



北京大学  
PEKING UNIVERSITY

---

# 实验物理中的统计方法

补充：向量微分间接

杨振伟

[yangzw@pku.edu.cn](mailto:yangzw@pku.edu.cn)

北京大学物理学院

---

# 要点

---

- 向量微分定义
- 标量函数对向量的梯度
- 向量函数对向量的梯度
- 向量微分常用公式
- 举例

# 提纲

---

- 很多实际问题涉及到向量微分
  - 可按分量展开解决
  - 但直接用向量微分会方便很多
- 函数对向量的微分形式与普通微分类似
- 向量微分的结果是向量或者矩阵，不论被求导的函数本身是标量函数还是矢量函数(或者矩阵)
- 本讲义以实函数为例

# 行向量和列向量的定义

---

## ➤ 行向量

$$\mathbf{x}^T \equiv [x_1, x_2, \dots, x_n] = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}^T$$

## ➤ 列向量

$$\mathbf{x} \equiv [x_1, x_2, \dots, x_n]^T = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$

# 向量微分的定义(1)

---

## ➤ 对列向量和行向量的微分（梯度）定义

### 对列向量的梯度：

相对于 $n \times 1$ 向量（列向量） $\mathbf{x}$  的梯度算子记作 $\nabla_{\mathbf{x}}$ ，定义为

$$\nabla_{\mathbf{x}} \equiv \left[ \frac{\partial}{\partial x_1}, \frac{\partial}{\partial x_2}, \dots, \frac{\partial}{\partial x_n} \right]^T = \frac{\partial}{\partial \mathbf{x}}$$

### 对行向量的梯度：

相对于 $1 \times n$ 向量（行向量） $\mathbf{x}^T$  的梯度算子记作 $\nabla_{\mathbf{x}^T}$ ，定义为

$$\nabla_{\mathbf{x}^T} \equiv \left[ \frac{\partial}{\partial x_1}, \frac{\partial}{\partial x_2}, \dots, \frac{\partial}{\partial x_n} \right] = \frac{\partial}{\partial \mathbf{x}^T}$$

# 标量函数对向量的梯度

---

所以，假设标量函数 $f(\mathbf{x})$ 以 $n$ 维列向量 $\mathbf{x}$ 为变元，其相对于 $\mathbf{x}$ 的梯度是 $n$ 维列向量：

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \left[ \frac{\partial f(\mathbf{x})}{\partial x_1}, \frac{\partial f(\mathbf{x})}{\partial x_2}, \dots, \frac{\partial f(\mathbf{x})}{\partial x_n} \right]^T = \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}}$$

而函数 $f(\mathbf{x})$ 相对于行向量 $\mathbf{x}^T$ 的梯度是 $n$ 维行向量：

$$\nabla_{\mathbf{x}^T} f(\mathbf{x}) = \left[ \frac{\partial f(\mathbf{x})}{\partial x_1}, \frac{\partial f(\mathbf{x})}{\partial x_2}, \dots, \frac{\partial f(\mathbf{x})}{\partial x_n} \right] = \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}^T}$$

- 1) 梯度的分量  $\frac{\partial f(\mathbf{x})}{\partial x_i}$  给出了  $f(\mathbf{x})$  在第  $i$  个方向上的变化率
  - 2) 标量函数对列向量的微分结果为列向量  
标量函数对行向量的微分结果为行向量

举例: 标量函数  $f(\mathbf{x}) = \mathbf{x}^T \mathbf{x} (= \sum_{i=1}^n x_i^2)$

---

求  $\frac{\partial f(\mathbf{x})}{\partial \mathbf{x}}$  和  $\frac{\partial f(\mathbf{x}^T)}{\partial \mathbf{x}^T}$ 。

解: 根据对列向量和行向量微分的定义,

$$\begin{aligned}\frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} &= \left[ \frac{\partial f(\mathbf{x})}{\partial x_1}, \frac{\partial f(\mathbf{x})}{\partial x_2}, \dots, \frac{\partial f(\mathbf{x})}{\partial x_n} \right]^T \\ &= [2x_1, 2x_2, \dots, 2x_n]^T = 2\mathbf{x} \text{ (列向量)}\end{aligned}$$

$$\begin{aligned}\frac{\partial f(\mathbf{x})}{\partial \mathbf{x}^T} &= \left[ \frac{\partial f(\mathbf{x})}{\partial x_1}, \frac{\partial f(\mathbf{x})}{\partial x_2}, \dots, \frac{\partial f(\mathbf{x})}{\partial x_n} \right] \\ &= [2x_1, 2x_2, \dots, 2x_n] = 2\mathbf{x}^T \text{ (行向量)}\end{aligned}$$

# 推广到矩阵函数(1)

---

$m$ 维行向量函数  $\mathbf{f}(\mathbf{x}) = [f_1(\mathbf{x}), f_2(\mathbf{x}), \dots, f_m(\mathbf{x})]$

相对于  $n$  维列向量  $\mathbf{x}$  的梯度是一个  $n \times m$  矩阵:

$$\frac{\partial \mathbf{f}(\mathbf{x})}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial f_1(\mathbf{x})}{\partial x_1} & \frac{\partial f_2(\mathbf{x})}{\partial x_1} & \cdots & \frac{\partial f_m(\mathbf{x})}{\partial x_1} \\ \frac{\partial f_1(\mathbf{x})}{\partial x_2} & \frac{\partial f_2(\mathbf{x})}{\partial x_2} & \cdots & \frac{\partial f_m(\mathbf{x})}{\partial x_2} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_1(\mathbf{x})}{\partial x_n} & \frac{\partial f_2(\mathbf{x})}{\partial x_n} & \cdots & \frac{\partial f_m(\mathbf{x})}{\partial x_n} \end{bmatrix} = \nabla_{\mathbf{x}} \mathbf{f}(\mathbf{x})$$



# 推广到矩阵函数(2)

---

$m$ 维列向量函数  $\mathbf{y}(\mathbf{x}) = [y_1(\mathbf{x}), y_2(\mathbf{x}), \dots, y_m(\mathbf{x})]^T$

相对于  $n$  维行向量  $\mathbf{x}^T$  的梯度是一个  $m \times n$  矩阵:

$$\frac{\partial \mathbf{y}(\mathbf{x})}{\partial \mathbf{x}^T} = \begin{bmatrix} \frac{\partial y_1(\mathbf{x})}{\partial x_1} & \frac{\partial y_1(\mathbf{x})}{\partial x_2} & \cdots & \frac{\partial y_1(\mathbf{x})}{\partial x_n} \\ \frac{\partial y_2(\mathbf{x})}{\partial x_1} & \frac{\partial y_2(\mathbf{x})}{\partial x_2} & \cdots & \frac{\partial y_2(\mathbf{x})}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial y_m(\mathbf{x})}{\partial x_1} & \frac{\partial y_m(\mathbf{x})}{\partial x_2} & \cdots & \frac{\partial y_m(\mathbf{x})}{\partial x_n} \end{bmatrix} = \nabla_{\mathbf{x}^T} \mathbf{y}(\mathbf{x})$$

这正是雅克比矩阵

再举例(1): 行向量函数  $f(\mathbf{x}) = \mathbf{x}^T$ , 求  $\frac{\partial f(\mathbf{x})}{\partial \mathbf{x}}$

---

$$\frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} = \frac{\partial \mathbf{x}^T}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial x_1}{\partial x_1} & \frac{\partial x_2}{\partial x_1} & \cdots & \frac{\partial x_n}{\partial x_1} \\ \frac{\partial x_1}{\partial x_2} & \frac{\partial x_2}{\partial x_2} & \cdots & \frac{\partial x_n}{\partial x_2} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial x_1}{\partial x_n} & \frac{\partial x_2}{\partial x_n} & \cdots & \frac{\partial x_n}{\partial x_n} \end{bmatrix} = \begin{bmatrix} 1, 0, \cdots, 0 \\ 0, 1, \cdots, 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0, 0, \cdots, 1 \end{bmatrix} = \mathbf{I}$$

再举例(2): 列向量函数  $\mathbf{g}(\mathbf{x}) = \mathbf{x}$ , 求  $\frac{\partial \mathbf{g}(\mathbf{x})}{\partial \mathbf{x}^T}$

---

$$\frac{\partial \mathbf{g}(\mathbf{x})}{\partial \mathbf{x}^T} = \frac{\partial \mathbf{x}}{\partial \mathbf{x}^T} = \begin{bmatrix} \frac{\partial x_1}{\partial x_1} & \frac{\partial x_2}{\partial x_1} & \cdots & \frac{\partial x_n}{\partial x_1} \\ \frac{\partial x_1}{\partial x_2} & \frac{\partial x_2}{\partial x_2} & \cdots & \frac{\partial x_n}{\partial x_2} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial x_1}{\partial x_n} & \frac{\partial x_2}{\partial x_n} & \cdots & \frac{\partial x_n}{\partial x_n} \end{bmatrix} = \begin{bmatrix} 1, 0, \cdots, 0 \\ 0, 1, \cdots, 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0, 0, \cdots, 1 \end{bmatrix} = \mathbf{I}$$

# 一些常用公式 (1)

---

$$(1) \frac{\partial \mathbf{x}^T}{\partial \mathbf{x}} = \mathbf{I}, \quad \frac{\partial \mathbf{x}}{\partial \mathbf{x}^T} = \mathbf{I}$$

若 $\mathbf{A}$ 为 $n$ 维方矩阵,  $\mathbf{y}$ 为 $n$ 维列向量, 且 $\mathbf{A}$ 和 $\mathbf{y}$ 都与 $\mathbf{x}$ 无关:

$$(2) \frac{\partial \mathbf{A}\mathbf{x}}{\partial \mathbf{x}^T} = \mathbf{A}, \quad \frac{\partial \mathbf{x}^T \mathbf{A}}{\partial \mathbf{x}} = \mathbf{A}$$

$$(3) \frac{\partial \mathbf{x}^T \mathbf{A} \mathbf{y}}{\partial \mathbf{x}} = \mathbf{A} \mathbf{y}, \quad \frac{\partial \mathbf{y}^T \mathbf{A} \mathbf{x}}{\partial \mathbf{x}} = \frac{\partial \mathbf{x}^T \mathbf{A}^T \mathbf{y}}{\partial \mathbf{x}} = \mathbf{A}^T \mathbf{y} (!!!)$$

$$(4) \frac{\partial \mathbf{x}^T \mathbf{A} \mathbf{x}}{\partial \mathbf{x}} = \mathbf{A} \mathbf{x} + \mathbf{A}^T \mathbf{x}$$

# 一些常用公式(2)

---

形式上，普通微分的一些法则都适用于向量微分，如

$$(1) f(\mathbf{x}) = c \Rightarrow \frac{\partial c}{\partial \mathbf{x}} = 0$$

$$(2) \frac{\partial [c_1 f(\mathbf{x}) + c_2 g(\mathbf{x})]}{\partial \mathbf{x}} = c_1 \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} + c_2 \frac{\partial g(\mathbf{x})}{\partial \mathbf{x}}$$

$$(3) \frac{\partial [f(\mathbf{x})g(\mathbf{x})]}{\partial \mathbf{x}} = \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} g(\mathbf{x}) + f(\mathbf{x}) \frac{\partial g(\mathbf{x})}{\partial \mathbf{x}}$$

$$(4) \frac{\partial}{\partial \mathbf{x}} \left[ \frac{f(\mathbf{x})}{g(\mathbf{x})} \right] = \frac{1}{g^2(\mathbf{x})} \left[ \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} g(\mathbf{x}) - f(\mathbf{x}) \frac{\partial g(\mathbf{x})}{\partial \mathbf{x}} \right]$$

$$(5) \frac{\partial f(\mathbf{y}(\mathbf{x}))}{\partial \mathbf{x}} = \frac{\partial \mathbf{y}^T(\mathbf{x})}{\partial \mathbf{x}} \frac{\partial f(\mathbf{y})}{\partial \mathbf{y}}$$

# 例: 多维随机变量的线性变换的概率密度

---

假设 $n$ 维随机变量 $\mathbf{x} = (x_1, \dots, x_n)^T$ 的联合概率密度为 $f(\mathbf{x})$ , 变量 $\mathbf{y} = (y_1, \dots, y_n)$ 是 $\mathbf{x}$ 的线性变换,  $\mathbf{y} = \mathbf{A}\mathbf{x}$ , 即

$$y_i = \sum_{j=1}^n A_{ij}x_j.$$

假设逆变换 $\mathbf{x} = \mathbf{A}^{-1}\mathbf{y}$ 存在。

- (a) 证明 $\mathbf{y}$ 的联合概率密度为 $g(\mathbf{y}) = f(\mathbf{A}^{-1}\mathbf{x})|\det(\mathbf{A}^{-1})|$ 。
- (b) 当 $\mathbf{A}$ 是正交矩阵时, 即 $\mathbf{A}^{-1} = \mathbf{A}^T$ , 求 $g(\mathbf{y})$

---

解：(a) 根据 *Statistical Data Analysis* (G. Cowan) 的式(1.37)，在逆变换  $\mathbf{x} = \mathbf{A}^{-1}\mathbf{y}$  存在的情况下， $\mathbf{y} = \mathbf{A}\mathbf{x}$  的联合概率密度为

$$g(\mathbf{y}) = f(\mathbf{x})|J| = f(\mathbf{A}^{-1}\mathbf{y})|J|$$

其中  $J$  是 Jacobian 行列式，即

$$J = \det\left(\frac{\partial \mathbf{x}}{\partial \mathbf{y}^T}\right) = \det\left(\frac{\partial \mathbf{A}^{-1}\mathbf{y}}{\partial \mathbf{y}^T}\right) = \det(\mathbf{A}^{-1})$$

所以， $g(\mathbf{y}) = f(\mathbf{A}^{-1}\mathbf{y})|J| = f(\mathbf{A}^{-1}\mathbf{y})|\det(\mathbf{A}^{-1})|$ 。

(b) 当  $\mathbf{A}$  是正交矩阵时，即  $\mathbf{A}^{-1} = \mathbf{A}^T$ 。

由  $\det(\mathbf{AB}) = \det(\mathbf{A})\det(\mathbf{B})$  和  $\det(\mathbf{A}^T) = \det(\mathbf{A})$ ，可得

$$1 = \det(\mathbf{I}) = \det(\mathbf{A}^{-1}\mathbf{A}) = \det(\mathbf{A}^T\mathbf{A}) = \det(\mathbf{A}^T)\det(\mathbf{A}) = (\det(\mathbf{A}^T))^2$$

所以， $|\det(\mathbf{A}^{-1})| = |\det(\mathbf{A}^T)| = 1$ ，即

$$g(\mathbf{y}) = f(\mathbf{A}^{-1}\mathbf{y})$$

这比用分量形式简洁很多。

---

# 参考资料

---

**《矩阵分析与应用》(2004), 张贤达, 清华大学出版社 (第5.1.2节)**