



# 实验物理中的统计方法

第一章：基本概念

杨振伟

# 本章要点

---

## ➤ 概率的定义与诠释

- 随机事件
- 概率的定义
- 条件概率
- 概率的诠释
- 贝叶斯定理
- 全概率定理

## ➤ 随机变量与概率密度

## ➤ 随机变量的函数

## ➤ 期待值、方差

## ➤ 不确定度的传递

---

什么是概率？

# 生活中的概率统计问题：摇号2018

---

## 北京普通小汽车摇号

### 北京市小客车指标调控管理信息系统

#### 个人普通指标配置

期号：201804

描述：2018年第04期个人普通小客车指标配置结果

指标配置日期：2018-08-26

实际指标配置时间：2018-08-26 10:15:42

有效编码总数：13603346

指标配置总数：6333

$$p \approx 0.05\%$$

指标配置种子数：269109

如果一直保持相同的中签概率，100次不中签的概率？

# 生活中的概率统计问题：摇号2021

---

## 北京普通小汽车摇号

### 北京市小客车指标调控管理信息系统

#### 家庭和个人普通指标配置

期号：202101

描述：2021年第01期家庭和个人普通小客车指标配置结果

指标配置日期：2021-06-26

实际指标配置时间：2021-06-26 10:07:51

基数序号总数：39624353

指标配置总数：19100

指标配置种子数：413238

$$p \approx 0.048\%$$

### 北京市小客车指标调控管理信息系统

#### 家庭和个人普通指标配置

期号：202102

描述：2021年第02期家庭和个人普通小客车指标配置结果

指标配置日期：2021-12-26

实际指标配置时间：2021-12-26 10:06:50

基数序号总数：43040012

指标配置总数：19100

指标配置种子数：757380

$$p \approx 0.044\%$$

如果一直保持相同的中签概率，100次不中签的概率？

# 生活中的概率统计问题：摇号2023

---

## 北京普通小汽车摇号

### 2023年第01期家庭和个人普通小客车指标配置结果

配置时间：2023-06-26 10:08:15

基数序号总数：49145235

指标配置总数：14300

指标配置种子数：317744

$$p \approx 0.029\%$$

### 2023年第02期家庭和个人普通小客车指标配置结果

配置时间：2023-12-26 10:07:37

基数序号总数：52541681

指标配置总数：14300

指标配置种子数：898617

$$p \approx 0.027\%$$

如果一直保持相同的中签概率，100次不中签的概率？

# 生活中的概率统计问题

“花伴侣” 中这些可信度什么意思？



# 随机事件

---

在一定的实验条件下，现象 $A$ 可能发生，也可能不发生，并且只有发生或不发生这样两种可能性，这是偶然现象中一种比较简单的情形，我们把发生了现象 $A$ 的事例称为随机事件 $A$ ，简称事件 $A$ 。随机事件也称随机事例。



# 概率的定义

## 柯尔莫哥洛夫公理

考虑一全集 $S$ , 有子集  $A, B, \dots$

1.  $P(A) \geq 0, \forall A \subset S$
2.  $P(S) = 1$
3.  $P(A \cup B) = P(A) + P(B)$ : 如果  $A \cap B = \emptyset$



→  $P(A)$ 称为事件 $A$ 的概率


利用柯氏三公理可以得到

$$P(\bar{A}) = 1 - P(A)$$


$$P(A \cup \bar{A}) = 1$$

$$A \subset B \Rightarrow P(A) \leq P(B)$$

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$



# 更数学化的描述



1933年柯尔莫哥洛夫 (Kolmogorov)  
基于集合论, 给出了**概率的公理化定义**。

设 $S$ 为样本空间,  $\mathcal{F}$ 是由 $S$ 的某些子集组成的一个事件域。如果对任意事件 $A \in \mathcal{F}$ , 定义在 $\mathcal{F}$ 上的一个实值函数 $P(A)$ 满足:

- (1) 非负性公理: 若 $A \in \mathcal{F}$ , 则 $P(A) \geq 0$ ;
- (2) 正则性 (规范性) 公理:  $P(S) = 1$ ;
- (3) 可列可加性公理: 若 $A_1, A_2, \dots, A_n, \dots$ 互斥, 则
$$P(\cup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i);$$

则称 $P(A)$ 为事件 $A$ 的**概率**。三元素 $(S, \mathcal{F}, P)$ 称为**概率空间**。

# 概率的本质

---

概率的公理化定义描述了概率的本质：

概率是事件（集合）的函数。

若在事件域  $\mathcal{F}$  上给出一个函数，只要这个函数满足柯氏公理，就可以称该函数为概率。

可以证明历史上出现过的频率定义、几何定义、古典定义、主观定义等，均满足柯氏公理。更准确地说，这些定义是概率的不同解释。

# 条件概率与独立性

---

给定事件 $B$ 的条件下，事件 $A$ 发生的条件概率定义为

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

要求  $P(B) \neq 0$

如果  $P(A \cap B) = P(A)P(B)$ ，则称  $A$ 与 $B$ 相互独立。

如果 $A$ 与 $B$ 相互独立，则

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{P(A)P(B)}{P(B)} = P(A)$$



$A$ 发生的概率与 $B$ 是否发生没有关系

# 条件概率与独立性

---

问题：假设两个子集 $A$ 和 $B$ 满足  $A \cap B = \emptyset$ ,  
那么 $A$ 和 $B$ 是否相互独立？

注意：两个子集互斥与独立定义不同。  
互斥的两个事件必然相互不独立，其中一个事件发生，则另一个事件必然不发生。

# 概率的诠释

---

## ➤ 相对频率（频率论者）

假设 $A, B, \dots$  是可重复实验的一组结果，则概率是

$$P(A) = \lim_{n \rightarrow \infty} \frac{n_A}{n}$$

$n_A$ :  $n$ 次重复实验中 $A$ 出现的次数

$n$ : 重复实验的次数

例如，量子力学、粒子散射、辐射衰变、宇宙线等

问题：相对频率的概率诠释满足柯氏公理吗？

# 概率的诠释

---

## ➤ 主观概率 (贝叶斯论者)

如果 $A, B, \dots$ 是一些假设(真或假的一些陈述), 那么概率

$P(A)$  = 对 $A$ 为真的信心程度(degree of belief)

✓ 两种解释皆与柯尔莫哥洛夫公理相符。

✓ 粒子物理与核物理实验中常用相对频率解释, 但是主观概率对不可重复现象可以提供更自然的处理:

系统不确定度, 某个粒子存在的概率, 置信区间的解释, .....

# 频率概率中的问题

---

- 实际问题中，统计量总是有限的。 $P(A)$ 完全取决于 $A$ 的划分与总统计量的大小。

概率大小会出现波动。

- 频率的概率解释不适用于某些特殊情况，例如

如何理解天气预报“明天降水概率60%”？

如何理解顶夸克质量的测量结果  $m_t = 173.49 \pm 1.07 \text{ GeV}/c^2$  ？



# 主观概率的一些特点

---

- 主观概率有一些吸引人的地方，例如对于不可重复现象的处理中，显得比较自然
- 系统误差(重复实验时仍保持不变);
  - 在某个事例出现的粒子是正电子;
  - 自然界是超对称的;
  - 明天将下雨(将来事件的不确定性);
  - 公元1500年元月一日北京下雨(过去事件的不确定性)。

结论中包含了主观上对事件为真的信念!

# 贝叶斯定理

---

假设 $P(A) \neq 0$ 且 $P(B) \neq 0$ ，根据条件概率的定义

$$P(A|B) = \frac{P(A \cap B)}{P(B)} \quad \text{与} \quad P(B|A) = \frac{P(B \cap A)}{P(A)}$$

利用  $P(A \cap B) = P(B \cap A)$ ，可得

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{P(B|A)P(A)}{P(B)}$$




贝叶斯 (1702-1761)

这就是**贝叶斯定理**，Reverend Thomas Bayes 首先提出。

# 全概率定律

考虑样本空间 $S$ 的一个子集 $B$ 。  
将样本空间划分为互斥的子集 $A_i$ ，  
使得  $\cup_i A_i = S$ 。



$$B = B \cap S = B \cap (\cup_i A_i) = \cup_i (B \cap A_i) ,$$

$$P(B) = P(\cup_i (B \cap A_i)) = \sum_i P(B \cap A_i)$$

$$= \sum_i P(B|A_i)P(A_i)$$

利用条件概率公式

全概率定律

贝叶斯定理  $\longrightarrow$

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)} = \frac{P(B|A)P(A)}{\sum_i P(B|A_i)P(A_i)}$$

# 贝叶斯理论与主观概率

## ➤ 贝叶斯理论通常用于主观概率问题

$$P(\text{理论}|\text{实验}) = \frac{P(\text{实验}|\text{理论})}{P(\text{实验})} \cdot P(\text{理论})$$

验后概率                      似然性                      先验概率

这是个“认识-实践-再认识-再实践”的迭代过程：



- 如果实验证明  $P(\text{理论}|\text{实验}) = 0$ ，则表明理论不能接受
- 大的  $P(\text{理论}|\text{实验})$  会增加对理论的信任度
- 通过实验结果可以修改  $P(\text{理论})$
- 改进的  $P(\text{理论})$  可应用于对重复实验结果的预测
- $P(\text{理论}|\text{实验})$  对先验理论的依赖将最终消失

# 例：如何利用贝叶斯定理

---

假设对任意一个人而言，感染上nCov的概率为

$$P(\text{nCov}) = 0.001$$

$$P(\text{no nCov}) = 0.999$$

验前概率，即任何检验之前

任何一次nCov检查的结果只有阴性(-)或阳性(+)两种

$$P(+|\text{nCov}) = 0.98$$

nCov感染患者阳性的概率

$$P(-|\text{nCov}) = 0.02$$

nCov感染患者阴性的概率

$$P(+|\text{no nCov}) = 0.03$$

nCov未感染患者阳性的概率

$$P(-|\text{no nCov}) = 0.97$$

nCov未感染患者阴性的概率

如果某人检查结果为阳性(+), 而他却觉得自己无明显感染渠道。那么他是否应担心自己真的感染了nCov?

# 例：如何利用贝叶斯定理(续)

我们想求的是验后概率  $P(\text{nCov}|+)$ ，即阳性结果条件下是nCov患者的概率。

利用贝叶斯定理，

nCoV患者阳性

$$P(\text{nCov}|+) = \frac{P(+|\text{nCov})P(\text{nCov})}{\underbrace{P(+|\text{nCov})P(\text{nCov}) + P(+|\text{no nCov})P(\text{no nCov})}_{\text{所有为阳性结果的人}}} = \frac{0.98 \times 0.001}{0.98 \times 0.001 + 0.03 \times 0.999} = 0.032$$

也就是说，你可能没什么问题！？

从个人角度看：对自己染上nCov结果的可信度为3.2%。  
从医生角度看：象这样的人有3.2%感染上了AIDS。




涉及到如何诠释结果（概率）的问题！

# 例：蒲丰投针

- 1777年,法国科学家蒲丰(Buffon)提出了投针试验问题.平面上画有等距离为 $a(>0)$ 的一些平行直线,现向此平面任意投掷一根长为 $b(<a)$ 的针,试求针与任一平行直线相交的概率。

解

以  $x$  表示针投到平面上时, 针的中点  $M$  到最近一条平行线的距离,



$\varphi$ 表示该针与该平行直线夹角,

那么针落在平面上的位置可由 $(x, \varphi)$ 完全确定。

# 例：蒲丰投针（续）

投针实验的所有可能结果与矩形区域

$$S = \left\{ (x, \varphi) \mid 0 \leq x \leq \frac{a}{2}, 0 \leq \varphi \leq \pi \right\}$$

中的所有点一一对应



所关心的事件

$$A = \{ \text{针与任一平行直线相交} \}$$

发生的充分必要条件为满足

$$0 \leq x \leq \frac{b}{2} \sin \varphi, 0 \leq \varphi \leq \pi$$

由投掷的任意性可知，这是一个几何概型问题。






# 例：蒲丰投针（续）

$$P(A) = \frac{m(G)}{m(S)} = \frac{G \text{ 的面积}}{S \text{ 的面积}}$$

$$= \frac{\int_0^\pi \frac{b}{2} \sin \varphi d\varphi}{\frac{a}{2} \times \pi}$$

$$= \frac{b}{\frac{a}{2} \times \pi} = \frac{2b}{a\pi}$$



# 例：蒙提霍尔问题

---

- 蒙提霍尔问题，亦称蒙特霍问题或三门问题（英文：Monty Hall problem），是一个源自博弈论的数学游戏问题，以美国的电视游戏节目 *Let's Make a Deal* 而闻名。问题的名字来自该节目的主持人蒙提·霍尔（Monty Hall）。



# 例：蒙提霍尔问题

- 参赛者可看见三扇关闭的门，其中一扇门后面有一辆汽车，选中它即可赢得汽车；另外两扇门后面各藏有一只山羊。参赛者先选定一扇门，但在开启之前，知情的主持人会在其余两扇门中打开一个后面是山羊的门，并讯问参赛者是否更换其选择的门。  
问题是：参赛者更换选择是否会增加赢得汽车的机会？



# 例：蒙提霍尔问题

---

## 三门问题的贝叶斯解法：

不失一般性，可以始终将嘉宾选择的门标记为“1”，将主持人打开的门标记为“3”，将剩下的门标记为“2”。

第  $i$  个门后面是汽车的先验概率为

$$P(T_i) = 1/3$$

如果汽车在1号门，主持人打开3号门的条件概率为

$$P(O_3|T_1) = 1/2$$

如果汽车在2号门，主持人打开3号门的条件概率为

$$P(O_3|T_2) = 1$$

如果汽车在3号门，主持人打开3号门的条件概率为

$$P(O_3|T_3) = 0$$

---

# 例：蒙提霍尔问题

---

由贝叶斯定理，主持人打开3号门的条件下，在1号门和2号门发现汽车的条件概率分别为：

$$\begin{aligned} P(T_1|O_3) &= \frac{P(O_3|T_1)P(T_1)}{\sum_{i=1}^3 P(O_3|T_i)P(T_i)} = \frac{P(O_3|T_1)}{\sum_{i=1}^3 P(O_3|T_i)} \\ &= \frac{\frac{1}{2}}{\frac{1}{2} + 1 + 0} = \frac{1}{3} \end{aligned}$$

$$\begin{aligned} P(T_2|O_3) &= \frac{P(O_3|T_2)P(T_2)}{\sum_{i=1}^3 P(O_3|T_i)P(T_i)} = \frac{P(O_3|T_2)}{\sum_{i=1}^3 P(O_3|T_i)} \\ &= \frac{1}{\frac{1}{2} + 1 + 0} = \frac{2}{3} \end{aligned}$$

所以，嘉宾变更选择后获得汽车的概率更大。

# 案例分析：探测器触发效率

---

大型强子对撞机上的质子束流每 25 ns 对撞一次，即事例率为40 MHz。假如每次对撞探测器的数据需占用约 1 MB 磁盘空间，那么每秒钟需要记录40 TB。这显然不现实。

好在对撞事例中产生我们关心的信号的概率很小（假设约 $10^{-6}$ ），因此可在硬件上编程设置一些筛选条件，只记录满足筛选条件的事例。这些筛选条件被称为“触发（trigger）”条件，应尽量满足：

- 1) 信号被保留下来的概率尽量大（触发效率高）；
- 2) 本底被保留下来的概率尽量小；
- 3) 响应时间不能太长。

假设一级触发要求信号被保留下来的概率（效率）不低于99%，本底被保留下来的概率不高于 $10^{-4}$ 。

求记录下来的事例中有多大概率是信号？

# 案例分析：探测器触发效率

**解** 用“sig”表示对撞中产生了信号；“bkg”表示对撞中没有信号产生，即只有本底；“w”表示对撞事例被记录了下来。

显然  $P(\text{sig}) = 10^{-6}$ ,  $P(\text{bkg}) = 1 - 10^{-6}$ ;

$P(w|\text{sig}) = 0.95$ ,  $P(w|\text{bkg}) = 10^{-4}$ 。

记录下来的事例为信号的概率为

$$\begin{aligned} P(\text{sig}|w) &= \frac{P(w|\text{sig})P(\text{sig})}{P(w|\text{sig})P(\text{sig}) + P(w|\text{bkg})P(\text{bkg})} \\ &= \frac{0.99 \times 10^{-6}}{0.99 \times 10^{-6} + 10^{-4} \times (1 - 10^{-6})} \\ &= 9.8 \times 10^{-3} \end{aligned}$$

即，记录下来的数据只有不到1%的事例含有信号。

“触发”的概念在很多领域都会用，例如各种类型的“预警”。

# 案例分析：古玩多贋品

---

假设古董市场中：

真货概率  $P(\text{真货}) = 10^{-5}$ ,

假货概率  $P(\text{假货}) = 1 - P(\text{真货}) = 0.99999$ 。

如果古董被鉴别为真货，记为事件 $T$ ，被鉴别为假货，记为事件 $F$ 。

假设某资深玩家对古董鉴别能力比较高，当古董为真货时该玩家将其鉴别为真的条件概率为 $P(T|\text{真货}) = 0.999$ ，当古董为假货时，将其鉴别为真的条件概率为 $P(T|\text{假货}) = 0.01$ 。

那么，对任意一个古董，假如该玩家认为这是真古董，那么该古董实际上为假货的概率是多少？



# 案例分析：古玩多赝品

---

解：需要计算的是，在鉴别为真货的条件下古董实际上为假货的条件概率 $P(\text{假货}|T)$ ，用贝叶斯定理：

$$\begin{aligned}P(\text{假货}|T) &= \frac{P(T|\text{假货})P(\text{假货})}{P(T|\text{假货})P(\text{假货}) + P(T|\text{真货})P(\text{真货})} \\&= \frac{0.01 \times 0.99999}{0.01 \times 0.99999 + 0.999 \times 10^{-5}} \\&= 0.999\end{aligned}$$

真相：该资深玩家仔细鉴别后买下的古董中，真货的概率仅0.1%。

# 本章要点

---

## ➤ 概率的定义与诠释

## ➤ 随机变量与概率密度

- 随机变量
- 概率密度、直方图
- 联合概率密度
- 边缘概率密度
- 条件概率密度

## ➤ 随机变量的函数

## ➤ 期待值、方差

## ➤ 不确定度的传递

# 随机变量和概率密度函数

- 随机变量是样本空间元素的实值单值函数，可以是离散函数，也可以是连续函数

假设实验结果为连续值  $x$ ， $x$  在  $[x, x + dx]$  区间内的概率为

$$P(x \in [x, x + dx]) = f(x)dx$$



$f(x)$  为概率密度函数(pdf)

$$\int_{-\infty}^{+\infty} f(x)dx = 1$$

归一化：  $x$  一定是某个实数

对于离散结果  $x_i$  ( $i = 1, 2, \dots$ ):

$$P(x_i) = p_i$$

概率质量函数(pmf)

$$\sum_i P(x_i) = 1$$

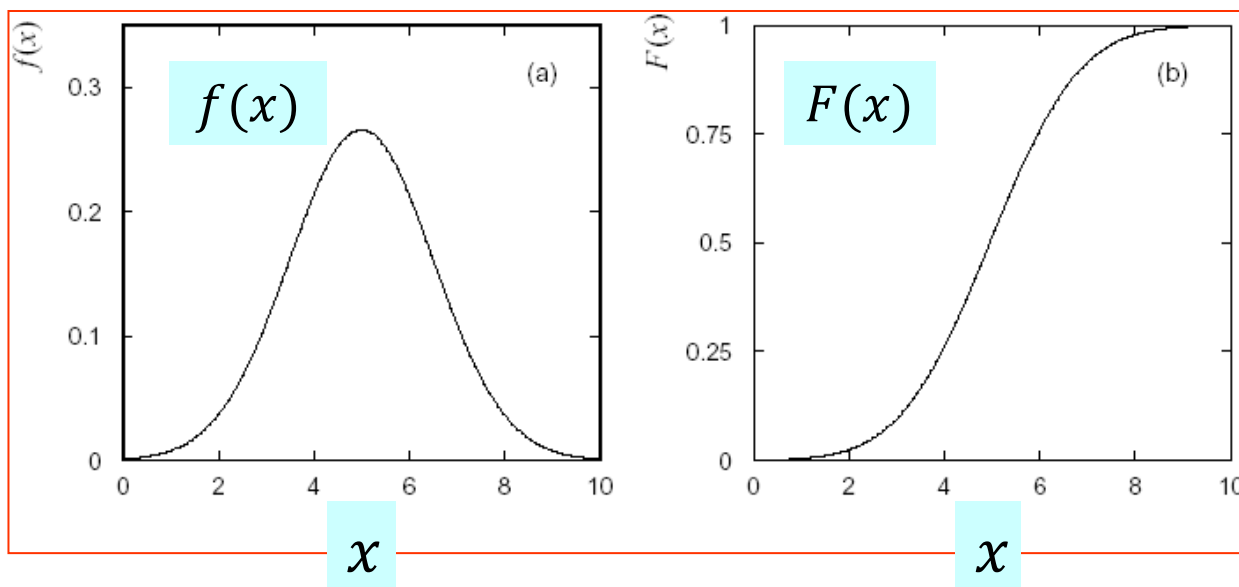
归一化

# 累积分布函数

- 实验结果小于等于  $x$  的概率

$$\int_{-\infty}^x f(x') dx' \equiv F(x)$$

累积分布函数(cdf)



- 概率密度函数可以定义为

$$f(x) = \frac{\partial F(x)}{\partial x}$$

# $\alpha$ 分位数、中位数与众数

---

分位数  $x_\alpha$  定义为随机变量  $x$  的值，它使得

$$F(x_\alpha) = \alpha \quad (0 \leq \alpha \leq 1)$$

因此容易求出分位点

$$x_\alpha = F^{-1}(\alpha)$$

$\alpha$ 分位数 ( $\alpha$ -quantile)  
中位数 (median)  
模 (mode)

随机变量  $x$  的中位数定义为

$$x_{1/2} = F^{-1}(1/2)$$

随机变量  $x$  被观测到大于或小于中位数的概率相等。

众数定义为使概率密度函数值达到极大的随机变量值。

# $\alpha$ 分位数 (quantile)


设 $X$ 为随机变量,  $0 < \alpha < 1$ , 若 $x_\alpha$ 满足

$$P(X \leq x_\alpha) = F(x_\alpha) = \alpha$$


则称 $x_\alpha$ 为 $X$ 的 $\alpha$ -分位数, 亦称下侧 $\alpha$ -分位数。若 $x'_\alpha$ 满足

$$P(X \geq x'_\alpha) = \alpha$$

则 $x'_\alpha$ 被称为上侧 $\alpha$ -分位数。



下侧 $\alpha$ -分位数



上侧 $\alpha$ -分位数

对连续变量 $x'_\alpha = x_{1-\alpha}$ ,  $x_\alpha = x'_{1-\alpha}$

# 中位数 (median) 与众数 (mode)

---

随机变量  $X$  的中位数 (或中值) 定义为

$$x_{1/2} = F^{-1}(1/2)$$


随机变量  $X$  被观测到大于或小于中位数的概率相等。

注意中位数与均值的区别。

众数定义为使概率密度函数值达到极大的随机变量值。  
众数也被称为最可几值。

# 直方图与概率密度函数

- 概率密度函数 p.d.f. 就是拥有无穷大样本，区间宽度为零，而且归一化到单位面积的直方图。




$$f(x) = \frac{N(x)}{n \cdot \Delta x}$$

$N(x)$  = 每个区间的频数

$n$  = 填入直方图的总事例数

$\Delta x$  = 区间的宽度



$$n \rightarrow \infty, \Delta x \rightarrow 0$$


$$n \cdot \Delta x \text{ 有限}$$

直方图在统计分析中非常重要，应准确理解它的含义。



# 多变量情形

观测量不止一个，例如  $x$  与  $y$



$$P(A \cap B) = \int \int f(x, y) dx dy$$

$f(x, y)$  = 联合概率密度函数

$$\iint f(x, y) dx dy = 1$$

# 边缘概率密度


有时，我们只关心某个分量的pdf:

$$\begin{aligned} P(A) &= \sum_i P(A \cap B_i) \\ &= \sum_i \int_{B_i} f(x, y) dy dx \\ &\rightarrow \int f(x, y) dy dx \end{aligned}$$

$$f_x(x) = \int f(x, y) dy$$

类似地

$$f_y(y) = \int f(x, y) dx$$

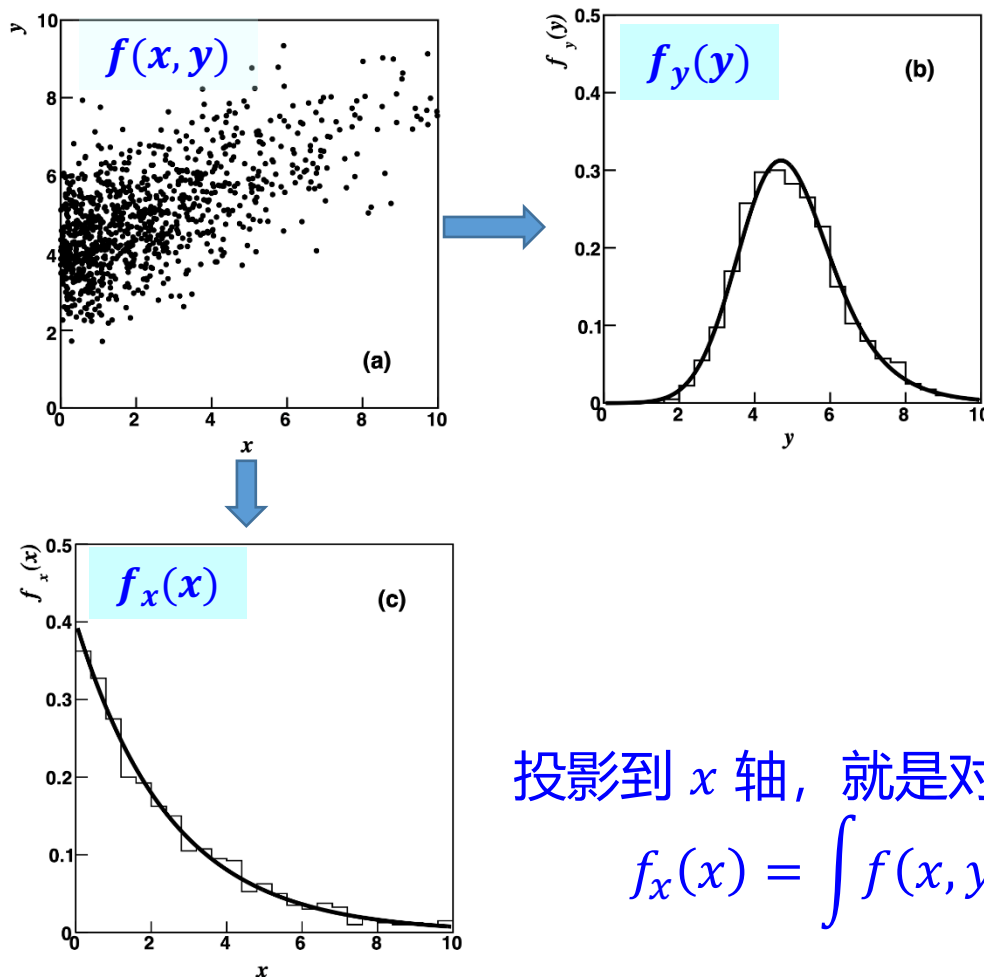


边缘概率密度

如果  $f(x, y) = f_x(x)f_y(y)$ , 则称随机变量  $x$  和  $y$  相互独立

# 边缘概率密度

边缘概率密度：将联合概率密度投影某个坐标轴



投影到  $y$  轴，就是对  $x$  积分：

$$f_y(y) = \int f(x, y) dx$$

投影到  $x$  轴，就是对  $y$  积分：

$$f_x(x) = \int f(x, y) dy$$

# 条件概率密度函数

有时，我们关心联合pdf中某个变量为常数的情况。

→ 条件概率

根据条件概率的定义：

$$P(B|A) = \frac{P(A \cap B)}{P(A)} = \frac{\int f(x, y) dx dy}{\int f_x(x) dx}$$

条件概率密度函数

$$h(y|x) = \frac{f(x, y)}{f_x(x)}, \quad g(x|y) = \frac{f(x, y)}{f_y(y)}$$

贝叶斯定理可写为

$$g(x|y) = \frac{h(y|x)f_x(x)}{f_y(y)}$$

如果  $f(x, y) = f_x(x)f_y(y)$ ，则  $x, y$  相互独立。

如果  $P(A \cap B) = P(A)P(B)$ ，则  $A, B$  相互独立。

# 条件概率密度函数(续)



例如, 已知联合概率密度  $f(x, y)$ 。  
求条件概率密度  $h(y|x_1)$ ,  $h(y|x_2)$ 。

做法:

1. 将  $f(x, y)$  中的  $x$  固定为  $x_1$  或  $x_2$ ,
2. 除以相应的边缘概率密度  $f_x(x_1)$  或  $f_x(x_2)$ , 以保证归一化条件

$$h(y|x_1) = \frac{f(x_1, y)}{f_x(x_1)}$$

$$h(y|x_2) = \frac{f(x_2, y)}{f_x(x_2)}$$



# 本章要点

---

## ➤ 概率的定义与诠释

## ➤ 随机变量与概率密度

## ➤ 随机变量的函数

- 一维随机变量的函数
- 多维随机变量的函数
- 梅林卷积、傅立叶卷积
- 雅克比行列式

## ➤ 期待值、方差

## ➤ 不确定度的传递

# 数据分析中的问题

粒子物理与核物理实验中对动量的测量通常是分别测量

$$p_T = \sqrt{p_x^2 + p_y^2} \quad p_z \quad f(p_T, p_z)$$

在已知两分量测量值的概率密度函数情况下，总动量为

$$p = \sqrt{p_T^2 + p_z^2}$$

如何导出总动量的测量值的概率密度函数？

$g(p)$

是研究随机变量函数的p.d.f问题。


随机变量的函数自身也是一个随机变量。

例如，  
 $\theta$ 和 $\cos \theta$

# 一维随机变量的函数

假设  $x$  服从概率密度  $f(x)$ ，对于函数  $a(x)$ ，其概率密度  $g(a)$  为何？

假设函数  $a(x)$  单调。



$a \in [a, a + da]$  的概率  $g(a)da$  等于  $x \in dS$  的概率  $f(x)dx$

$dS$ : 满足  $a \in [a, a + da]$  的  $x$  的集合

$$\begin{aligned} g(a)da &= \int_{dS} f(x)dx \\ &= \left| \int_{x(a)}^{x(a+da)} f(x')dx' \right| \\ &= \int_{x(a)}^{x(a) + \left| \frac{dx}{da} \right| da} f(x')dx' \end{aligned}$$


$$\Rightarrow g(a) = f(x(a)) \left| \frac{dx}{da} \right|$$



# 函数的逆不唯一情况

假如  $a(x)$  的逆不唯一,  $dS$  将包含多段  $dx$  区间, 需要全部考虑进来

例如:  $a = x^2$ ,  $x = \pm\sqrt{a}$ ,  $dx = \pm \frac{da}{2\sqrt{a}}$



$$g(a)da = \int_{dS} f(x)dx$$

$$dS = \left[ \sqrt{a}, \sqrt{a} + \frac{da}{2\sqrt{a}} \right] \cup \left[ -\sqrt{a} - \frac{da}{2\sqrt{a}}, \sqrt{a} \right]$$

$$g(a) = \frac{f(\sqrt{a})}{2\sqrt{a}} + \frac{f(-\sqrt{a})}{2\sqrt{a}}$$

# 多维随机变量的函数

---

考虑多维随机变量  $\vec{x} = (x_1, \dots, x_n)$  与函数  $a(\vec{x})$ 。

已知  $\vec{x}$  的概率密度  $f(\vec{x}) = f(x_1, \dots, x_n)$ , 求  $a$  的概率密度  $g(a)$

$$g(a')da' = \int \cdots \int_{dS} f(x_1, \dots, x_n) dx_1 \cdots dx_n$$

$dS$ : 在  $a(\vec{x}) = a'$  和  $a(\vec{x}) = a' + da'$  定义的两个曲面之间的  $\vec{x}$  空间范围

# 多维随机变量的函数: $z = xy$

如果两个随机变量  $x, y > 0$ , 服从联合概率密度  $f(x, y)$ , 考虑函数  $z = xy$ , 其概率密度函数  $g(z)$  是什么形式?

$$g(z)dz = \iint_{dS} f(x, y) dx dy = \int_0^\infty dx \int_{z/x}^{(z+dz)/x} f(x, y) dy$$


$$= \int_0^\infty dx \left[ f\left(x, \frac{z}{x}\right) \frac{dz}{x} \right]$$

$$= \left[ \int_0^\infty f\left(x, \frac{z}{x}\right) \frac{dx}{x} \right] dz$$

$$g(z) = \int_0^\infty f\left(x, \frac{z}{x}\right) \frac{dx}{x}$$

$$g(z) = \int_0^\infty f\left(\frac{z}{y}, y\right) \frac{dy}{y}$$

给定  $x$ ,  
当  $z \in (z, z + dz)$  时,  
 $y \in \left(\frac{z}{x}, \frac{z+dz}{x}\right)$ 。



# 多维随机变量的函数: $z = x + y$

如果两个随机变量  $x, y > 0$ , 服从联合概率密度  $f(x, y)$ , 考虑函数  $z = x + y$ , 其概率密度函数  $g(z)$  是什么形式?

$$\begin{aligned} g(z)dz &= \iint_{dS} f(x, y) dx dy = \int_0^\infty dx \int_{z-x}^{z+dz-x} f(x, y) dy \\ &= \int_0^\infty dx [f(x, z-x) dz] \\ &= \left[ \int_0^\infty f(x, z-x) dx \right] dz \end{aligned}$$

给定  $x$ ,  
当  $z \in (z, z + dz)$  时,  
 $y \in (z - x, z + dz - x)$ 。



$$g(z) = \int_0^\infty f(x, z-x) dx$$

$$g(z) = \int_0^\infty f(z-y, y) dy$$

# 梅林卷积与傅立叶卷积

---

假设随机变量  $x, y$  相互独立, 分别服从  $g(x)$  和  $h(y)$  分布。

$z = xy$  的概率密度函数  $f(z)$  是什么形式?

$$f(z) = \int_{-\infty}^{+\infty} g(x) h\left(\frac{z}{x}\right) \frac{dx}{|x|} = \int_{-\infty}^{+\infty} g\left(\frac{z}{y}\right) h(y) \frac{dy}{|y|}$$



梅林(Mellin)卷积

$$f = g \otimes h$$

$z = x + y$  的概率密度函数  $f(z)$  是什么形式?

$$f(z) = \int_{-\infty}^{+\infty} g(x) h(z - x) dx = \int_{-\infty}^{+\infty} g(z - y) h(y) dy$$



傅立叶(Fourier)卷积

$$f = g \otimes h$$

# 多维随机变量的函数与雅可比行列式

考虑随机矢量  $\vec{x} = (x_1, \dots, x_n)$ , 联合概率密度为  $f(\vec{x})$ , 构造  $n$  个线性独立的函数  $\vec{a}(\vec{x}) = (a_1(\vec{x}), \dots, a_n(\vec{x}))$ , 并且其逆函数  $x_1(\vec{a}), \dots, x_n(\vec{a})$  存在。

则  $\vec{a}$  的联合概率密度为

$$g(\vec{a}) = |J| f(\vec{x})$$

其中  $J$  是雅可比行列式

$$J = \begin{vmatrix} \frac{\partial x_1}{\partial a_1} & \frac{\partial x_1}{\partial a_2} & \cdots & \frac{\partial x_1}{\partial a_n} \\ \frac{\partial x_2}{\partial a_1} & \frac{\partial x_2}{\partial a_2} & \cdots & \frac{\partial x_2}{\partial a_n} \\ \vdots & & & \vdots \\ & & \cdots & \frac{\partial x_n}{\partial a_n} \end{vmatrix}$$

对联合概率密度  $g(\vec{a})$  积分掉其他不关心的变量, 可以得到任意一个边缘概率密度  $g_i(a_i)$ 。  
这是数据分析中误差传递的基础。

# 例：坐标变换

---

在物理测量中，经常需要直角坐标系和极坐标系互换。假设 $x$ 和 $y$ 是相互独立的随机变量，均服从 $N(0,1)$ 分布。试证明变换为极坐标 $(\rho, \varphi)$ 后， $(\rho, \varphi)$ 仍为相互独立的随机变量。其中

$$\rho = \sqrt{x^2 + y^2}, \quad \rho > 0$$

$$\varphi = \operatorname{arctg}\left(\frac{y}{x}\right), \quad \varphi \in [0, 2\pi]$$

# 坐标变换

---

证明：利用变量变换法求解。

$(x, y)$ 的联合密度函数为  $f(x, y) = \frac{1}{2\pi} e^{-\frac{(x^2+y^2)}{2}}$

$\rho$ 和 $\varphi$ 的反函数分别为,  $x = \rho \cos \varphi$  和  $y = \rho \sin \varphi$ 。

雅克比行列式

$$J = \begin{vmatrix} \frac{\partial x}{\partial \rho} & \frac{\partial y}{\partial \rho} \\ \frac{\partial x}{\partial \varphi} & \frac{\partial y}{\partial \varphi} \end{vmatrix} = \begin{vmatrix} \cos \varphi & \sin \varphi \\ -\rho \sin \varphi & \rho \cos \varphi \end{vmatrix} = -\rho$$



# 坐标变换

---

因此 $(\rho, \varphi)$ 的联合密度函数为

$$\begin{aligned} f(\rho, \varphi) &= f(x(\rho, \varphi), y(\rho, \varphi))|J| \\ &= \frac{1}{\sqrt{2\pi}} e^{-\frac{(\rho \sin \varphi)^2}{2}} \cdot \frac{1}{\sqrt{2\pi}} e^{-\frac{(\rho \cos \varphi)^2}{2}} \cdot \rho \\ &= \frac{1}{2\pi} \rho e^{-\frac{\rho^2}{2}} \quad \rho \geq 0, \quad 0 \leq \varphi \leq 2\pi \end{aligned}$$

由于联合密度函数与 $\varphi$ 无关，根据随机变量相互独立的定义， $\rho$ 与 $\varphi$ 必然相互独立。

# 坐标变换

---

$$f(\rho, \varphi) = \frac{1}{2\pi} \rho e^{-\frac{\rho^2}{2}} \quad \rho \geq 0, \quad 0 \leq \varphi \leq 2\pi$$

对 $f(\rho, \varphi)$ 关于 $\varphi$ 求积分, 得到 $\rho$ 的边缘密度函数:

$$f(\rho) = \int_0^{2\pi} \frac{1}{2\pi} \rho e^{-\frac{\rho^2}{2}} d\varphi = \rho e^{-\frac{\rho^2}{2}}, \quad (\rho \geq 0)$$

(著名的瑞利分布)

对 $f(\rho, \varphi)$ 关于 $\rho$ 求积分, 得到 $\varphi$ 的边缘密度函数:

$$f(\varphi) = \int_0^{\infty} \frac{1}{2\pi} \rho e^{-\frac{\rho^2}{2}} d\rho = \frac{1}{2\pi}, \quad (\varphi \in [0, 2\pi])$$

# 本章要点

---

- 概率的定义与诠释
- 随机变量与概率密度
- 随机变量的函数
- 期待值、方差
  - 均值、方差、标准差
  - 协方差、相关系数
- 不确定度的传递

# 期待值、方差、标准差

考虑概率密度为  $f(x)$  的随机变量  $x$ ，定义期待 (平均) 值为

$$E[x] = \int x f(x) dx$$

通常记为:  $E[x] = \mu$

意为pdf的“重心”

对离散型变量, 有  $E[x] = \sum_{i=1}^n x_i P(x_i)$


对概率密度为  $g(y)$  的函数  $y(x)$ , 有

$$E[y] = \int y g(y) dy = \int y(x) f(x) dx$$

方差定义为  $V[x] = E[(x - E[x])^2] = E[x^2] - \mu^2$

通常记为:  $V[x] = \sigma^2$

标准差:  $\sigma \equiv \sqrt{\sigma^2}$



# 协方差与相关系数

定义协方差  $\text{cov}[x, y]$  (也可用矩阵  $V_{xy}$  表示)为

$$\text{cov}[x, y] = E[(x - \mu_x)(y - \mu_y)] = E[xy] - \mu_x\mu_y$$

相关系数定义为

$$\rho_{xy} = \frac{\text{cov}[x, y]}{\sigma_x \sigma_y} \quad \text{无量纲}$$





如果  $x, y$  相互独立, 即

$$f(x, y) = f_x(x)f_y(y)$$

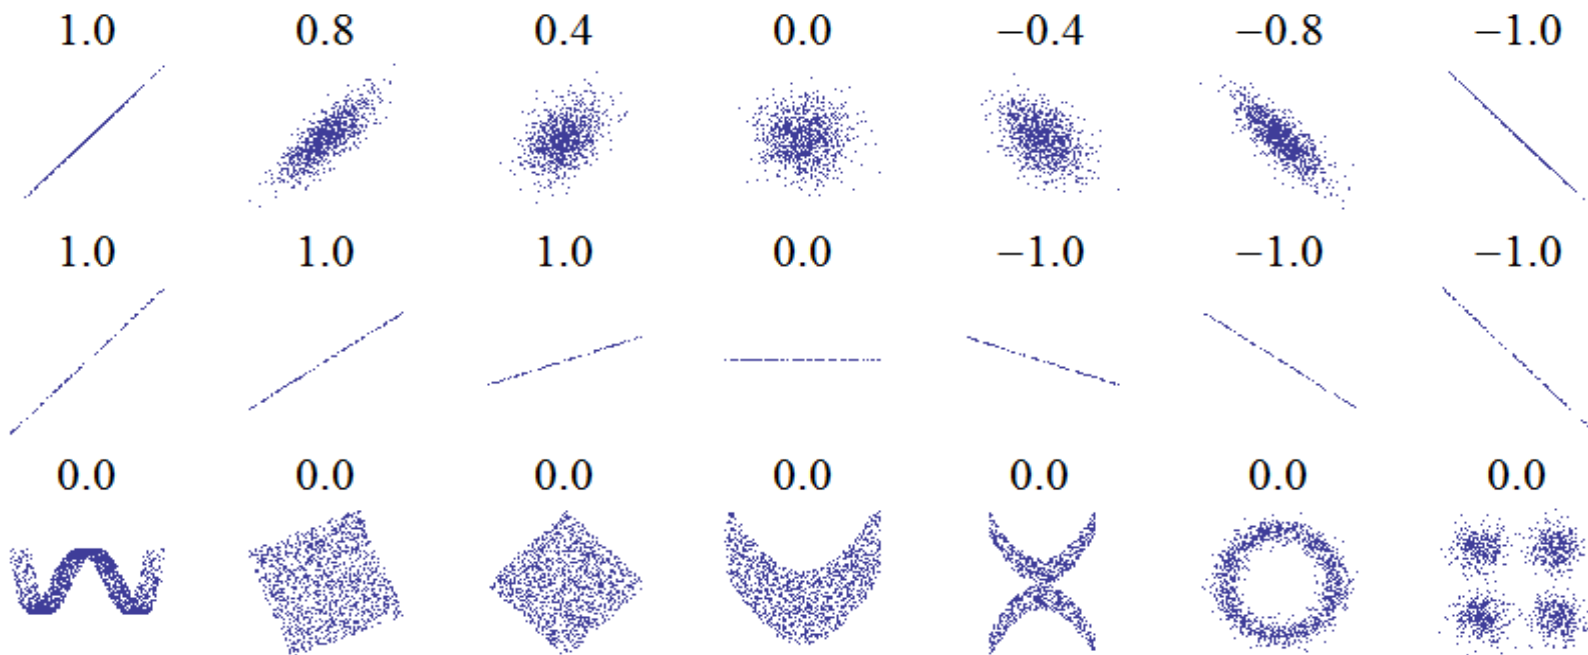
$$E[xy] = \iint xyf(x, y)dxdy = \mu_x\mu_y$$

则  $\text{cov}[x, y] = 0 \rightarrow \rho_{xy} = 0$

即  $x, y$  不相关



# 相关性的例子



$\rho = 0$ , 但显然有一定的相关性



相关性的其他定义

$$\rho_{xy} = \frac{\text{cov}[x, y]}{\sigma_x \sigma_y}$$


皮尔逊相关系数

# 秩相关性 (rank correlation)

- 比较两个样本的排序  
➔ 可以更好地度量相关性

- 两种主要的秩相关系数:

- Spearman's rho
- Kendall's tau



Spearman's rho

$$r_s = \rho_{R(X), R(Y)} = \frac{\text{cov}(R(X), R(Y))}{\sigma_{R(X)} \sigma_{R(Y)}}$$

# 原点矩和中心矩

---

设 $X$ 为随机变量， $k$ 为正整数。若以下数学期望均存在，则称

$$\mu_k = E(X^k)$$

为 $X$ 的 $k$ 阶原点矩。称

$$\nu_k = E[(X - E(X))^k]$$

为 $X$ 的 $k$ 阶中心矩。

1阶原点矩为数学期望，2阶中心矩为方差。

中心矩与原点矩的关系：

$$\nu_k = E[(X - E(X))^k] = E[(X - \mu_1)^k] = \sum_{i=0}^k C_k^i \mu_i (-\mu_1)^{k-i}$$



# 其他特征数

- **变异系数**：设 $X$ 为随机变量，且方差存在。则称  $C_V = \frac{\sqrt{\text{Var}(X)}}{E(X)}$  为 $X$ 的**变异系数**。

$C_V$  是无量纲量，用于比较量纲不同的随机变量的波动大小。

- **偏度系数**：设随机变量 $X$ 的前三阶矩存在，则比值  $\beta_S = \frac{v_3}{v_2^{3/2}} = \frac{E[(X-E(X))^3]}{[\text{Var}(X)]^{3/2}}$  被称为 $X$ 的**偏度系数**，简称**偏度**。或记为 $\gamma_1$ 。

$\beta_S$ 描述分布偏离对称性的程度。



$\beta_S > 0$ 称该分布为**正偏**或**右偏**； $\beta_S < 0$ 称该分布为**负偏**或**左偏**。

- **峰度系数**：设随机变量 $X$ 的前四阶矩存在，则  $\beta_k = \frac{v_4}{v_2^2} - 3 = \frac{E[(X-E(X))^4]}{[\text{Var}(X)]^2} - 3$  被称为 $X$ 的**峰度系数**，简称**峰度**。或记为 $\gamma_2$ 。



峰度描述分布的尖峭程度或尾部粗细程度，正态分布 $\beta_k = 0$ 。

# 偏度系数和峰度系数

➤  $\beta_S$ 描述分布偏离对称性的程度



➤ 峰度描述分布的尖峭程度或尾部粗细程度，正态分布  $\beta_k = 0$  。



# 特征函数

---

设  $X$  是一个随机变量, 则称  $e^{itX}$  的数学期望值, 即

$$\varphi(t) = E[e^{itX}], \quad -\infty < t < \infty$$

为随机变量  $X$  的特征函数。

对连续变量,

$$\varphi(t) = \int_{-\infty}^{\infty} e^{itx} f(x) dx$$

这实际上是概率密度函数  $f(x)$  的傅里叶变换。

对离散变量,

$$\varphi(t) = \sum_{k=0}^{\infty} e^{itx_k} p_k$$

由于  $|e^{itX}| = 1$ , 随机变量  $X$  的特征函数总是存在。

# 特征函数的性质

---

1.  $|\varphi(t)| \leq \varphi(0) = 1$

2.  $\varphi(-t) = \overline{\varphi(t)}$

3.  $\varphi_{aX+b}(t) = e^{ibt} \varphi_X(at)$

4. 若随机变量 $X$ 与 $Y$ 独立, 则

$$\varphi_{X+Y}(t) = \varphi_X(t)\varphi_Y(t)$$

5. 若 $E(X^l)$ 存在, 则

$$\varphi^{(k)}(0) = i^k E[X^k], \quad 0 \leq k \leq l$$

因此, 可以通过特征函数的导数求随机变量的矩:

$$E[X^k] = \frac{\varphi^{(k)}(0)}{i^k}$$

# 特征函数的性质 (续)

---

1. 一致连续性

2. 非负定性

3. 逆转公式:

设 $F(x)$ 和 $\varphi(t)$ 分别为随机变量 $X$ 的分布函数和特征函数, 则对 $F(x)$ 的任意两个连续点 $x_1 < x_2$ , 有

$$F(x_2) - F(x_1) = \lim_{\tau \rightarrow \infty} \frac{1}{2\pi} \int_{-\tau}^{\tau} \frac{e^{-itx_1} - e^{-itx_2}}{it} \varphi(t) dt$$

4. 唯一性:

随机变量的分布函数由其特征函数唯一确定。

5. 若 $X$ 为连续随机变量, 其密度函数为 $f(x)$ , 特征函数为 $\varphi(t)$ , 若 $\int_{-\infty}^{\infty} |\varphi(t)| dt < \infty$ , 则

$$f(x) = \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{-itx} \varphi(t) dt$$

# 特征函数的用处

---

特征函数是处理概率论问题的有力工具，其作用在于：

- 可将卷积运算化成乘法运算；
- 可将求各阶矩的积分运算化成微分运算；
- 可将求随机变量序列的极限分布化成一般的函数极限问题；
- .....

# 本章要点

---

- 概率的定义与诠释
- 随机变量与概率密度
- 随机变量的函数
- 期待值、方差
- 不确定度的传递
  - 不确定度的传递
  - 不确定度与相关性
  - 正交变换消除相关性

# 不确定度的传递(1)

---

假设我们对某个量测量了一组值  $\vec{x} = (x_1, \dots, x_n)$ , 并得到其协方差  $V_{ij} = \text{cov}[x_i, x_j]$  (表征与  $x_i$  有关的测量不确定度)。

现考虑一函数  $y(\vec{x})$ , 如何求其方差  $V[y]$  ?

硬核计算法:

利用联合概率密度  $f(\vec{x})$  求  $y$  的概率密度  $g(y)$ , 然后计算

$$V[y] = E[y^2] - (E[y])^2$$

困难所在:

现实中通常不可行, 有时我们甚至完全清楚  $f(\vec{x})$  的形式。

有没有简单可行的方法呢?



# 不确定度的传递(2)

---

假设我们已知  $\vec{\mu} = E[\vec{x}]$ ,

现实中通常只能根据测量得到  $\vec{x}$  的估计

对  $y(\vec{x})$  在  $\vec{\mu}$  处作一阶泰勒展开,

$$y(\vec{x}) \approx y(\vec{\mu}) + \sum_{i=1}^n \left[ \frac{\partial y}{\partial x_i} \right]_{\vec{x}=\vec{\mu}} (x_i - \mu_i)$$

为了得到  $V[y]$ , 我们需要计算  $E[y^2]$  和  $E[y]$ 。

由于  $E[x_i - \mu_i] = 0$ ,  $E[y(\vec{x})] \approx y(\vec{\mu})$

# 不确定度的传递(3)

---

$$\begin{aligned} E[y^2] &\approx y^2(\mu^2) + 2y(\vec{\mu}) \sum_{i=1}^n \left[ \frac{\partial y}{\partial x_i} \right]_{\vec{x}=\vec{\mu}} E[x_i - \mu_i] \\ &\quad + E \left[ \left( \sum_{i=1}^n \left[ \frac{\partial y}{\partial x_i} \right]_{\vec{x}=\vec{\mu}} (x_i - \mu_i) \right) \left( \sum_{j=1}^n \left[ \frac{\partial y}{\partial x_j} \right]_{\vec{x}=\vec{\mu}} (x_j - \mu_j) \right) \right] \\ &= y^2(\mu^2) + 0 + E \left[ \sum_{i,j=1}^n \left[ \frac{\partial y}{\partial x_i} \frac{\partial y}{\partial x_j} \right]_{\vec{x}=\vec{\mu}} (x_i - \mu_i)(x_j - \mu_j) \right] \\ &= y^2(\mu^2) + \sum_{i,j=1}^n \left[ \frac{\partial y}{\partial x_i} \frac{\partial y}{\partial x_j} \right]_{\vec{x}=\vec{\mu}} V_{ij} \end{aligned}$$

因此,  $y(\vec{x})$  的方差为

$$\sigma_y^2 \approx \sum_{i,j=1}^n \left[ \frac{\partial y}{\partial x_i} \frac{\partial y}{\partial x_j} \right]_{\vec{x}=\vec{\mu}} V_{ij}$$

# 不确定度的传递(4)

---

如果  $x_i$  不相关, 即  $V_{ij} = \sigma_i^2 \delta_{ij}$ , 那么

$$\sigma_y^2 \approx \sum_{i=1}^n \left[ \frac{\partial y}{\partial x_i} \right]_{\vec{x}=\vec{\mu}}^2 \sigma_i^2$$

类似地, 对于  $m$  组函数  $\vec{y}(\vec{x}) = (y_1(\vec{x}), \dots, y_m(\vec{x}))$ ,

$$U_{kl} = \text{cov}[y_k, y_l] \approx \sum_{i,j=1}^n \left[ \frac{\partial y_k}{\partial x_i} \frac{\partial y_l}{\partial x_j} \right]_{\vec{x}=\vec{\mu}} V_{ij}$$

或者, 写成矩阵形式  $U = A V A^T$ , 其中

$$A_{ij} = \left[ \frac{\partial y_i}{\partial x_j} \right]_{\vec{x}=\vec{\mu}}$$



# 不确定度的传递(5)

不确定度传递公式告诉我们，如何用原始变量 $\vec{x}$ 的协方差表示一组函数 $\vec{y}(\vec{x}) = (y_1(\vec{x}), \dots, y_m(\vec{x}))$ 的协方差。

## 局限性

- 只有当  $\vec{y}(\vec{x})$  为线性时才严格成立；
- 如果函数在与  $\sigma_i$  差不多的范围内是非线性的，这个近似不再适用。

前面的推导对  $x_i$  的概率密度严格形式没有要求，例如，它可以不是高斯分布。



# 不确定度传递：特例

---

$$y = x_1 + x_2$$



$$\sigma_y^2 = \sigma_1^2 + \sigma_2^2 + 2\text{cov}[x_1, x_2]$$

$$y = x_1 x_2$$



$$\frac{\sigma_y^2}{y^2} = \frac{\sigma_1^2}{x_1^2} + \frac{\sigma_2^2}{x_2^2} + \frac{2\text{cov}[x_1, x_2]}{x_1 x_2}$$

如果  $x_i$  不相关：

- 和的不确定度的平方等于不确定度的平方和
- 积的相对不确定度的平方等于相对不确定度的平方和



注意：变量之间的相关性，可以引起巨大变化！

# 不确定度传递：特例

考虑  $y = x_1 - x_2$ ，其中： $\mu_1 = \mu_2 = 10$ ， $\sigma_1 = \sigma_2 = 1$ 。

1)  $\rho = \frac{\text{cov}[x_1, x_2]}{\sigma_1 \sigma_2} = 0$

$$V[y] = 1^2 + 1^2 = 2 \quad \longrightarrow \quad \sigma_y = 1.4$$

2)  $\rho = 1$

$$V[y] = 1^2 + 1^2 - 2 = 0 \quad \longrightarrow \quad \sigma_y = 0$$

即，对于 100% 相关的两个变量，其差的不确定度为零。

这种特征有时候是有益的：将共同的或难以估计的不确定度，通过适当的数学处理将它们消掉，达到减小不确定度的目的。

# 实践讨论题

---

- 利用普通的体重计称一个重量十公斤以内的物体，例如
  - 笔记本电脑
  - 装有大约10本书的书包
  - 行李箱
- 评价你的测量结果是否靠谱。如果不靠谱，有什么办法？



# 坐标变换下的不确定度矩阵

实验上测量带电粒子动量通常是，测量粒子在探测器中各点的击中坐标 $(x, y)$ ，然后拟合径迹。径迹往往用极坐标 $(r, \theta)$ 描述。一般来说， $(x, y)$ 的测量不相关。 $(r, \theta)$ 是否相关？

两种坐标的变换关系：

$$r^2 = x^2 + y^2, \quad \tan \theta = y/x$$

$$V_{xy} = \begin{bmatrix} \sigma_x^2 & 0 \\ 0 & \sigma_y^2 \end{bmatrix}$$

由于

$$U_{r\theta} = A V_{xy} A^T$$

$$A_{ij} = \left[ \frac{\partial y_i}{\partial x_j} \right]_{\vec{x}=\vec{\mu}} \Rightarrow A = \begin{bmatrix} \frac{x}{r} & \frac{y}{r} \\ -\frac{y}{r^2} & \frac{x}{r^2} \end{bmatrix}$$

坐标变换后的协方差矩阵为





$$U_{r\theta} = \begin{bmatrix} \frac{x}{r} & \frac{y}{r} \\ -\frac{y}{r^2} & \frac{x}{r^2} \end{bmatrix} \begin{bmatrix} \sigma_x^2 & 0 \\ 0 & \sigma_y^2 \end{bmatrix} \begin{bmatrix} \frac{x}{r} & -\frac{y}{r^2} \\ \frac{y}{r} & \frac{x}{r^2} \end{bmatrix} = \frac{1}{r^2} \begin{bmatrix} x^2 \sigma_x^2 + y^2 \sigma_y^2 & \frac{xy(\sigma_y^2 - \sigma_x^2)}{r} \\ \frac{xy(\sigma_y^2 - \sigma_x^2)}{r} & \frac{x^2 \sigma_x^2 + y^2 \sigma_y^2}{r^2} \end{bmatrix}$$

除非处处满足  $\sigma_x = \sigma_y$ ，否则  $(r, \theta)$  有相关性。



# 不同坐标系下相关性的变化

通过转动坐标，随机变量的相关性会发生改变。



显然，通过将坐标系转动  $45^\circ$ ，上面的相关性在新坐标系下消失。

# 正交变换消除随机变量间的相关性

假设有  $n$  个随机变量  $\vec{x} = (x_1, \dots, x_n)$  及其协方差矩阵  $V_{ij} = \text{cov}[x_i, x_j]$ , 可以证明, 能够通过线性变换重新定义  $n$  个新的变量  $\vec{y} = (y_1, \dots, y_n)$ , 使得对应的协方差矩阵  $U_{ij} = \text{cov}[y_i, y_j]$  非对角元为零。

令这个变换为  $y_i = \sum_{j=1}^n A_{ij} x_j$  或写成矩阵形式  $\vec{y} = A\vec{x}$

对应的协方差矩阵为

$$\begin{aligned} U_{ij} &= \text{cov}[y_i, y_j] \\ &= \\ \text{cov}\left[\sum_{k=1}^n A_{ik} x_k, \sum_{l=1}^n A_{jl} x_l\right] \\ &= \sum_{k,l=1}^n A_{ik} A_{jl} \text{cov}[x_k, x_l] \\ &= \sum_{k,l=1}^n A_{ik} A_{jl} V_{kl} \\ &= \sum_{k,l=1}^n A_{ik} V_{kl} A_{lj}^T \\ &= AVA^T \end{aligned}$$

非线性情况

$$\begin{aligned} U_{ij} &= \text{cov}[y_i, y_j] \\ &\approx \sum_{k,l=1}^n \left[ \frac{\partial y_i}{\partial x_k} \frac{\partial y_j}{\partial x_l} \right]_{\vec{x}=\vec{\mu}} V_{kl} \end{aligned}$$

目标: 使矩阵  $U$  为对角矩阵

# 对角化变换后变量的协方差矩阵

选取适当的 $A$ 使协方差矩阵  $U = AVA^T$  对角化

先确定协方差矩阵  $V$  的本征列矢量  $\vec{r}^i$  ( $i = 1, \dots, n$ )。解方程

$$V\vec{r}^i = \lambda_i\vec{r}^i \quad \text{或} \quad V_{kl}r_l^i = \lambda_i r_k^i$$

由于协方差矩阵总是对称的，可知本征矢量是正交的

$$\vec{r}^i \cdot \vec{r}^j = \sum_{k=1}^n r_k^i r_k^j = \delta_{ij}$$


变换矩阵  $A$  由本征矢量  $\vec{r}$  给出，即

$$\sum_{j=1}^n A_{ij}A_{jk}^T = \sum_{j=1}^n A_{ij}A_{jk}^T = \sum_{j=1}^n r_j^i r_j^k = \vec{r}^i \cdot \vec{r}^k = \delta_{ik}$$

# 正交变换后变量的协方差矩阵

因此，正则变换的协方差矩阵为

$$\begin{aligned} U_{ij} &= \sum_{k,l=1}^n A_{ik} V_{kl} A_{lj}^T \\ &= \sum_{k,l=1}^n r_k^i V_{kl} r_l^j \\ &= \sum_{k=1}^n r_k^i \lambda_j r_k^j \\ &= \lambda_j \vec{r}^i \cdot \vec{r}^j \\ &= \lambda_j \delta_{ij} \end{aligned}$$




正交变换后，变量的方差由原协方差矩阵  $V$  的本征值给出。

对应于矢量的转动  
不改变模的大小。



$$|\vec{y}|^2 = \vec{y}^T \vec{y} = \vec{x}^T A^T A \vec{x} = |\vec{x}|^2$$

尽管不相关的变量往往容易处理，但是对经过变换的变量的理解不一定容易。

# 带电粒子在闪烁体的射程



PHYSICAL REVIEW D 77, 052003 (2008)



在原来的定义下，可以得到粒子射程随动量大小的变化关系。通过转动变换，粒子的射程与动量发生了改变，没有物理含义，但是提供了一个很好的粒子类型甄别变量。

# 小结

---

## ➤ 概率的定义与诠释

- 随机事件
- 概率的定义与诠释（相对频率、主观）
- 条件概率、贝叶斯定理、全概率定理

## ➤ 随机变量与概率密度

- 随机变量、概率密度、直方图
- 联合概率密度、边缘概率密度、条件概率密度

## ➤ 随机变量的函数

- 一维（多维）随机变量的函数
- 梅林卷积、傅立叶卷积、雅克比行列式

## ➤ 期待值、方差

- 均值、方差、标准差
- 协方差、相关系数

## ➤ 不确定度的传递

- 不确定度的传递、不确定度与相关性
- 正交变换消除相关性