



实验物理中的统计方法

第九章：置信区间

杨振伟

回顾

□ 矩的定义

用样本的 k 阶矩代替总体的 k 阶矩，解方程组

□ 矩方法估计量及其应用

□ 矩方法与最大似然法和最小二乘法的比较

本章要点

- 统计不确定度中的标准差问题
- 经典置信区间问题
- 利用似然函数或二乘函数确定置信区间
- 贝叶斯上限
- 物理发现或上限的检验统计量

测量结果的表述与含义

实验数据: x_1, \dots, x_n  实验目的: 估计参数 $\theta \rightarrow \hat{\theta}_{\text{obs}}$

还应该给出 $\hat{\theta}$ 的方差, 即 $\hat{\sigma}_{\hat{\theta}}^2$ 。结果应该报告成如下形式

$$\hat{\theta}_{\text{obs}} \pm \hat{\sigma}_{\hat{\theta}} = 5.73 \pm 0.21$$

其真正的含义是什么呢?

如果我们知道 $\hat{\theta}_{\text{obs}}$ 服从某概率密度 $g(\hat{\theta}; \theta)$, 那么上述结果的正确表述应该是

θ 的估计值为 5.73

$\sigma_{\hat{\theta}}$ 的估计值为 0.21



$\sigma_{\hat{\theta}}$ 描述 $g(\hat{\theta}; \theta)$ 的分布宽度

参数估计值的分布


通常参数估计值服从的概率密度 $g(\hat{\vec{\theta}}; \vec{\theta})$ 是多维高斯分布
 $\hat{\vec{\theta}}$ 和 $\hat{V} = \widehat{\text{cov}}[\hat{\theta}_i, \hat{\theta}_j]$ 综合了我们对 $g(\hat{\vec{\theta}}; \vec{\theta})$ 的了解或估计



可以用来作为不确定度传递的输入参量，
以及用最小二乘法求平均值等等。

可按照约定报道不确定度，而不管概率密度 $g(\hat{\theta}; \theta)$ 的形式。
只有在需要对不同实验求平均时，其形式才会发挥作用。

如果 $g(\hat{\theta}; \theta)$ 是高斯形式，则置信区间可以表述为

$[\hat{\theta}_{\text{obs}} - \hat{\sigma}_{\hat{\theta}}, \hat{\theta}_{\text{obs}} + \hat{\sigma}_{\hat{\theta}}]$  68.3% 置信区间范围。

如果 $g(\hat{\theta}; \theta)$ 不是高斯形式



中心置信区间应给出不对称的不确定度

区间估计

除了参数的“点估计”，还应当报道反映其统计不确定度的一个区间 (interval)。

这个区间 (interval) 最好具有以下性质：

- 1) 客观地描述实验结果；
- 2) 以给定的概率包含参数真值；
- 3) 为给参数下结论提供必要的信息

经常用“ \pm 所得估计量的标准差”表示不确定度，但有时这种做法不适用：

估计值在物理边界附近，例如观测得到的事例率与零一致。

将简要介绍频率论区间（经典置信区间）和贝叶斯区间。

置信区间的定义

设 θ 是总体的一个待估参数, 其参数空间为 Θ , X_1, \dots, X_n 为来自总体的样本。对给定的实数 α ($0 < \alpha < 1$), 假设有两个统计量 $T_1(X_1, \dots, X_n)$, $T_2(X_1, \dots, X_n)$, 若对任意 $\theta \in \Theta$, 有

$$P(T_1 \leq \theta \leq T_2) \geq 1 - \alpha$$


则称随机区间 $[T_1, T_2]$ 为 θ 的置信水平为 $1 - \alpha$ 的置信区间或区间估计。

T_1 称为(双侧)置信下限, T_2 称为(双侧)置信上限。

若满足 $P(T_1 \leq \theta \leq T_2) = 1 - \alpha$, 则称 $[T_1, T_2]$ 为 θ 的 $1 - \alpha$ 同等置信区间。连续随机变量一般要求取等号。

置信区间的含义

置信水平 $1 - \alpha$ 的频率解释：在大量重复估计置信区间时，每次得到的样本观测值不同，从而每次得到的区间也不同。对每个区间而言，要么包含未知参数 θ 的真值，要么不包含。平均而言，在这些大量的区间中，至少有 $100(1 - \alpha)\%$ 个包含 θ 。



关于置信区间的几点说明

- 置信区间的长度 $T_2 - T_1$ 反映了估计精度
 - $T_2 - T_1$ 越小, 估计精度越高
- α 反映了估计的可靠度, α 越小, 越可靠
 - α 越小, $1 - \alpha$ 越大, 估计的可靠度越高;
但此时 $T_2 - T_1$ 往往增大, 因而估计精度降低

区间估计三部曲

- 选取枢轴量
- 由分位点的定义建立不等式
- 求解不等式得到下界 a 和上界 b

枢轴量

—— 仅含一个待估参数的
样本的连续函数

枢轴量的分布不依赖于未知参数。

例：正态分布均值的区间估计

➤ 已知 $X \sim N(\mu, 1)$ 。设样本容量为 $n = 5$ ：

$$(X_1, X_2, X_3, X_4, X_5)$$

求 μ 的置信水平为 $1 - \alpha = 95\%$ 的置信区间

$$\bar{X} \sim N\left(\mu, \frac{1}{5}\right) \Rightarrow \frac{\bar{X} - \mu}{\sqrt{1/5}} \sim N(0, 1)$$

枢轴量

取 $\alpha = 0.05$ ，查表或计算得 $Z_{\alpha/2} = 1.96$

$$P\left(\left|\frac{\bar{X} - \mu}{\sqrt{1/5}}\right| \geq 1.96\right) = 0.05$$

称随机区间 $(\bar{X} - 1.96\sqrt{1/5}, \bar{X} + 1.96\sqrt{1/5})$

为未知参数 μ 的置信度为0.95的置信区间。

若测得 一组样本值, 算得 $\bar{X} = 1.86$,

代入得到区间 **(0.983 , 2.737)**

此时, 有:

$$\begin{aligned} P(\bar{X} - 1.96\sqrt{1/5} \leq \mu \leq \bar{X} + 1.96\sqrt{1/5}) \\ = P(0.983 \leq \mu \leq 2.737) = 0.95 \end{aligned}$$

关于置信区间的构造的两点说明：

- 满足置信度要求的 a 与 b 通常不唯一。若有可能，应选平均长度 $E(T_2 - T_1)$ 达到最短的 a 与 b 。枢轴量 G 满足对称分布时通常容易实现。
- 实际中，选平均长度 $E(T_2 - T_1)$ 尽可能短的 a 与 b 往往不易实现。因此，常选择 a 与 b ，使得两个尾部概率各为 $\alpha/2$ ，即 $P(G < a) = P(G > b) = \alpha/2$ 。这样的置信区间称为等尾置信区间。在 G 为偏态分布时常采用这种方法。

频率论置信区间

假设参数 θ 的估计量为 $\hat{\theta}$ ，估计值为 $\hat{\theta}_{\text{obs}}$ 。


为了正确表述结果，还需要知道 $\hat{\theta}$ 的分布形式 $g(\hat{\theta}; \theta)$ 。

首先指定“上下尾部的概率”，如： $\alpha = \beta = 0.05$ ，

然后找到函数关系 $u_\alpha(\theta)$ 和 $v_\beta(\theta)$ ，使得

$$\begin{aligned}\alpha &= P(\hat{\theta} \geq u_\alpha(\theta)) = \int_{u_\alpha(\theta)}^{\infty} g(\hat{\theta}; \theta) d\hat{\theta} \\ &= 1 - G(u_\alpha(\theta); \theta)\end{aligned}$$

$$\begin{aligned}\beta &= P(\hat{\theta} \leq v_\beta(\theta)) = \int_{-\infty}^{v_\beta(\theta)} g(\hat{\theta}; \theta) d\hat{\theta} \\ &= G(v_\beta(\theta); \theta)\end{aligned}$$



$G(\hat{\theta}; \theta)$ 为概率密度 $g(\hat{\theta}; \theta)$ 的累积分布

参数置信带的定义

在 $u_\alpha(\theta)$ 和 $v_\beta(\theta)$ 之间的区域称为**置信带**。

无论 θ 为何值，在置信带找到 $\hat{\theta}_{\text{obs}}$ 的概率为

$$P(v_\beta(\theta) \leq \hat{\theta} \leq u_\alpha(\theta)) = 1 - \alpha - \beta$$

假设 $u_\alpha(\theta)$ 和 $v_\beta(\theta)$ 单调，则有反函数

$$\begin{aligned} a(\hat{\theta}) &\equiv u_\alpha^{-1}(\hat{\theta}), \\ b(\hat{\theta}) &\equiv v_\beta^{-1}(\hat{\theta}) \end{aligned}$$

不等式

$$\begin{aligned} \hat{\theta} &\geq u_\alpha(\theta), \\ \hat{\theta} &\leq v_\beta(\theta), \end{aligned}$$




$$\begin{aligned} a(\hat{\theta}) &\geq \theta, \\ b(\hat{\theta}) &\leq \theta \end{aligned}$$

$$\begin{aligned} P(\hat{\theta} \geq u_\alpha(\theta)) \\ P(\hat{\theta} \leq v_\beta(\theta)) \end{aligned}$$



$$\begin{aligned} P(a(\hat{\theta}) \geq \theta) \\ P(b(\hat{\theta}) \leq \theta) \end{aligned}$$



参数的置信区间确定

根据置信带的定义，有不等式

$$a(\hat{\theta}) \geq \theta, \quad b(\hat{\theta}) \leq \theta$$


$$P(a(\hat{\theta}) \geq \theta) = \alpha, \quad P(b(\hat{\theta}) \leq \theta) \leq \beta$$



或者合并成

$$P(a(\hat{\theta}) \leq \theta \leq b(\hat{\theta})) = 1 - \alpha - \beta$$

在真值 θ 未知的情况下，通过估计值 $\hat{\theta}$ 与函数 $a(\hat{\theta})$ 和 $b(\hat{\theta})$ 给出 θ 的置信区间。





置信区间的求解

求解置信区间 $[a, b]$ 的诀窍是求解下列方程：

$$\alpha = \int_{u_\alpha(\theta)}^{\infty} g(\hat{\theta}; \theta) d\hat{\theta} = \int_{\hat{\theta}_{\text{obs}}}^{\infty} g(\hat{\theta}; a) d\hat{\theta}$$
$$\beta = \int_{-\infty}^{v_\beta(\theta)} g(\hat{\theta}; \theta) d\hat{\theta} = \int_{-\infty}^{\hat{\theta}_{\text{obs}}} g(\hat{\theta}; b) d\hat{\theta}$$



$$a \equiv u_\alpha^{-1}(\hat{\theta}_{\text{obs}}),$$
$$b \equiv v_\beta^{-1}(\hat{\theta}_{\text{obs}})$$



a 是 θ 的假设值，使得： $P(\hat{\theta} > \hat{\theta}_{\text{obs}}) = \alpha$

b 是 θ 的假设值，使得： $P(\hat{\theta} < \hat{\theta}_{\text{obs}}) = \beta$

参数置信区间含义

注意，得到的区间是随机的，而真值 θ 是一个未知常数。

我们经常将置信区间 $[a, b]$ 报道为 $\hat{\theta} \pm_c^d$ ，即

$$c = \hat{\theta} - a, \quad d = b - \hat{\theta}$$

那么 $\hat{\theta} = 80.25_{-0.25}^{+0.31}$ 意味着什么呢？

它并不意味着任意一次实验：

$$P(80.00 < \theta < 80.56) = 1 - \alpha - \beta$$

它意味着：

重复样本容量相同的实验多次，每次按相同方法构造置信区间，那么，覆盖 θ 的置信区间占比为 $1 - \alpha - \beta$ 。

高斯分布估计量的置信区间

如果 $\hat{\theta}$ 服从

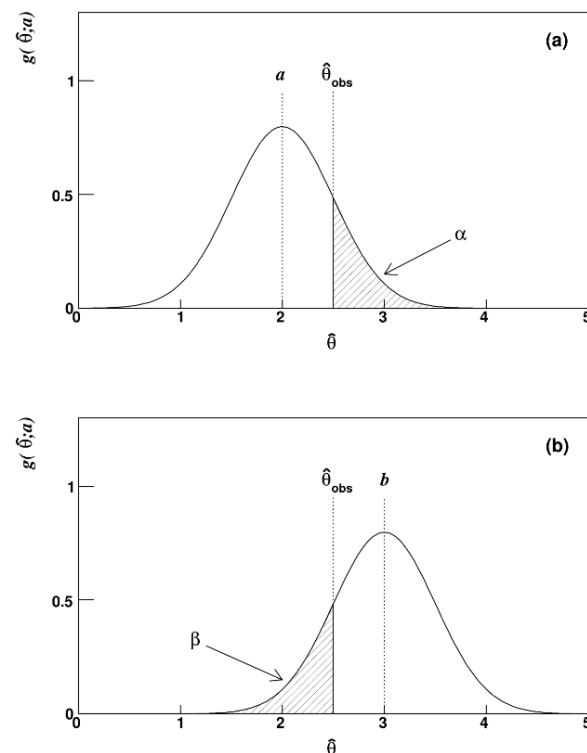
$$g(\hat{\theta}; \theta) = \frac{1}{\sqrt{2\pi\sigma_{\hat{\theta}}^2}} \exp\left(-\frac{(\hat{\theta} - \theta)^2}{2\sigma_{\hat{\theta}}^2}\right)$$

为了找到 θ 的置信区间，解下列方程

$$\alpha = 1 - G(\hat{\theta}_{\text{obs}}; a, \sigma_{\hat{\theta}}) = 1 - \Phi\left(\frac{\hat{\theta}_{\text{obs}} - a}{\sigma_{\hat{\theta}}}\right),$$
$$\beta = G(\hat{\theta}_{\text{obs}}; b, \sigma_{\hat{\theta}}) = \Phi\left(\frac{\hat{\theta}_{\text{obs}} - b}{\sigma_{\hat{\theta}}}\right)$$



a 与 b 的解



高斯分布的累积函数与分位点

前面的函数 G 是 $\hat{\theta}$ 的累积分布，且

$$\Phi(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-x'^2/2} dx'$$

是标准高斯的累积分布函数，可以证明

$$\begin{aligned} a &= \hat{\theta}_{\text{obs}} - \sigma_{\hat{\theta}} \Phi^{-1}(1 - \alpha), \\ b &= \hat{\theta}_{\text{obs}} + \sigma_{\hat{\theta}} \Phi^{-1}(1 - \beta) \end{aligned}$$

这里 Φ^{-1} 给出标准高斯的分位数（可以调用ROOT中的函数
`Double_t TMath::NormQuantile(Double_t p)`计算）




$$\Phi^{-1}(1 - \alpha), \quad \Phi^{-1}(1 - \beta)$$

给出 a 与 b 离 $\hat{\theta}$ 有多少倍标准差。

标准高斯的分位点

为了找到服从高斯分布的参数估计量的置信区间，需要确定下列分位点（取 $\alpha = \beta = \gamma/2$ ）




通常对分位点取整

中心

单边

$\Phi^{-1}\left(1-\frac{\gamma}{2}\right)$	$1-\gamma$	$\Phi^{-1}(1-\alpha)$	$1-\alpha$
1	0.6827	1	0.8413
2	0.9544	2	0.9772
3	0.9973	3	0.9987



有时对概率覆盖率取整

中心

单边

$1-\gamma$	$\Phi^{-1}\left(1-\frac{\gamma}{2}\right)$	$1-\alpha$	$\Phi^{-1}(1-\alpha)$
0.90	1.645	0.90	1.282
0.95	1.960	0.95	1.645
0.99	2.576	0.99	2.326

泊松分布均值的置信区间

假设 n 是泊松变量, $\hat{v} = n$, 估计值 $\hat{v}_{\text{obs}} = n_{\text{obs}}$,

$$P(n; v) = \frac{v^n}{n!} e^{-v}, \quad n = 0, 1, \dots$$

对于固定的 α, β , 由于 v 只能取离散值, 用来确定置信带的函数 $u_\alpha(v)$ 和 $v_\beta(v)$ 不一定对任意 v 都存在, 即不一定能找到整数 \hat{v} , 满足

$P(\hat{v} \geq u_\alpha(v)) = \alpha, P(\hat{v} \leq v_\beta(v)) = \beta$ 。此时, 可类似于前面提到的如下处理,

$$\begin{aligned} \alpha &= P(\hat{\theta} \geq u_\alpha(\theta)) \\ \beta &= P(\hat{\theta} \leq v_\beta(\theta)) \end{aligned} \iff \begin{aligned} \alpha &= P(a(\hat{\theta}) \geq \theta) \\ \beta &= P(b(\hat{\theta}) \leq \theta) \end{aligned}$$

考虑求解

$$\begin{aligned} \alpha &= P(\hat{v} \geq \hat{v}_{\text{obs}}; a) = 1 - \sum_{n=0}^{n_{\text{obs}}-1} \frac{a^n}{n!} e^{-a}, \\ \beta &= P(\hat{v} \leq \hat{v}_{\text{obs}}; b) = \sum_{n=0}^{n_{\text{obs}}} \frac{b^n}{n!} e^{-b}, \end{aligned}$$



a 与 b

a 是 v 的假设值, 使得: $P(\hat{v} \geq \hat{v}_{\text{obs}}) = \alpha$

b 是 v 的假设值, 使得: $P(\hat{v} \leq \hat{v}_{\text{obs}}) = \beta$


泊松分布均值的置信区间确定

利用

$$\sum_{n=0}^m \frac{v^n}{n!} e^{-v} = 1 - F_{\chi^2}(2v; n_d = 2(m + 1))$$

这里 F_{χ^2} 是自由度为 n_d 的卡方变量的累积分布函数。

$$\alpha = 1 - \sum_{n=0}^{n_{\text{obs}}-1} \frac{a^n}{n!} e^{-a},$$
$$\beta = \sum_{n=0}^{n_{\text{obs}}} \frac{b^n}{n!} e^{-b},$$



$$a = \frac{1}{2} F_{\chi^2}^{-1}(\alpha; n_d = 2n_{\text{obs}}),$$
$$b = \frac{1}{2} F_{\chi^2}^{-1}(1 - \beta; n_d = 2(n_{\text{obs}} + 1)),$$

这里 $F_{\chi^2}^{-1}$ 是卡方分布的分位数（可以调用ROOT中的函数

Double_t TMath::ChisquareQuantile(Double_t p, Double_t ndf)计算)

泊松求和与卡方分布积分关系的推导

$$\sum_{n=0}^m \frac{\nu^n}{n!} e^{-\nu} = \int_{2\nu}^{\infty} f_{\chi^2}(z; n_d = 2(m+1)) dz = 1 - F_{\chi^2}(2\nu; n_d = 2(m+1))$$

$$\text{已知 } f_{\chi^2}(z; n) = \frac{1}{2^{n/2} \Gamma(n/2)} z^{\frac{n}{2}-1} e^{-\frac{z}{2}}$$

$$\text{则 } f_{\chi^2}(z; 2(m+1)) = \frac{1}{2^{m+1} \Gamma(m+1)} z^m e^{-\frac{z}{2}} = \frac{1}{2} \frac{(z/2)^m}{m!} e^{-\frac{z}{2}}$$

$$\int_{2\nu}^{\infty} f_{\chi^2}(z; n_d = 2(m+1)) dz = \int_{2\nu}^{\infty} \frac{1}{2} \frac{(z/2)^m}{m!} e^{-\frac{z}{2}} dz = \int_{\nu}^{\infty} \frac{x^m}{m!} e^{-x} dx$$

对 $\int_{\nu}^{\infty} \frac{x^m}{m!} e^{-x} dx$ 反复用分部积分, 可得

$$\int_{\nu}^{\infty} \frac{x^m}{m!} e^{-x} dx = \frac{\nu^m}{m!} e^{-\nu} + \frac{\nu^{m-1}}{(m-1)!} e^{-\nu} + \cdots + \frac{\nu^1}{1!} e^{-\nu} + \frac{\nu^0}{0!} e^{-\nu} = \sum_{n=0}^m \frac{\nu^n}{n!} e^{-\nu}$$

泊松分布均值的置信水平上限值

重要特例: $n_{\text{obs}} = 0$

$$\beta = \sum_{n=0}^0 \frac{b^n}{n!} e^{-b} = e^{-b} \quad \Rightarrow \quad b = -\ln \beta$$

对于置信水平 $1 - \beta = 95\%$ 的上限,

$$\begin{aligned} b &= -\ln \beta \\ &= -\ln(0.05) \\ &= 2.996 \\ &\approx 3 \end{aligned}$$

n_{obs}	lower limit a			upper limit b		
	$\alpha = 0.1$	$\alpha = 0.05$	$\alpha = 0.01$	$\beta = 0.1$	$\beta = 0.05$	$\beta = 0.01$
0	—	—	—	2.30	3.00	4.61
1	0.105	0.051	0.010	3.89	4.74	6.64
2	0.532	0.355	0.149	5.32	6.30	8.41
3	1.10	0.818	0.436	6.68	7.75	10.04
4	1.74	1.37	0.823	7.99	9.15	11.60
5	2.43	1.97	1.28	9.27	10.51	13.11
6	3.15	2.61	1.79	10.53	11.84	14.57
7	3.89	3.29	2.33	11.77	13.15	16.00
8	4.66	3.98	2.91	12.99	14.43	17.40
9	5.43	4.70	3.51	14.21	15.71	18.78
10	6.22	5.43	4.13	15.41	16.96	20.14

反用检验得到置信区间

参数 θ 的置信区间可通过定义假设参数值 θ 的检验得到：

指定 θ “不偏好的” 数据值（临界域），使得
 $P(\text{数据在临界域}) \leq \gamma$ ， γ 为预先指定值，如 0.05 或 0.1。

反用检验来定义置信区间：

在置信水平 $1 - \gamma$ 的检验中不被拒绝的 θ 值的集合。

置信区间包含 θ 真值的概率大于等于 $1 - \gamma$ 。

等价于置信带的构造；置信带是检验的接受域。

反转正态分布均值检验得到置信区间

设 X_1, \dots, X_n 是来自 $N(\mu, \sigma^2)$ 的独立同分布 (iid) 。考虑检验 $H_0: \mu = \mu_0$ 对 $H_1: \mu \neq \mu_0$ 。对于固定的显著性水平 α ，一个合理的检验的拒绝域为

$$\left\{ \bar{x}: |\bar{x} - \mu_0| > \frac{Z_{\alpha/2}\sigma}{\sqrt{n}} \right\}$$

当 $|\bar{x} - \mu_0| \leq \frac{Z_{\alpha/2}\sigma}{\sqrt{n}}$ 时， H_0 被接受。

$$\begin{aligned} & P \left(|\bar{x} - \mu_0| \leq \frac{Z_{\alpha/2}\sigma}{\sqrt{n}} \mid \mu = \mu_0 \right) \\ &= P \left(\bar{x} - \frac{Z_{\alpha/2}\sigma}{\sqrt{n}} \leq \mu_0 \leq \bar{x} + \frac{Z_{\alpha/2}\sigma}{\sqrt{n}} \mid \mu = \mu_0 \right) = 1 - \alpha \end{aligned}$$


这对所有 μ 都成立，即

$$P \left(\bar{x} - \frac{Z_{\alpha/2}\sigma}{\sqrt{n}} \leq \mu \leq \bar{x} + \frac{Z_{\alpha/2}\sigma}{\sqrt{n}} \right) = 1 - \alpha$$

置信区间

置信区间与检验的接受域的关系

- 假设检验：固定参数并询问什么样本值（接受域 A ）与该固定值相符
- 置信区间：固定样本值并询问什么参数值（置信区间 C ）使该样本值好像最合理



置信区间与 p 值的关系

等价地，我们可以考虑每个假设的 θ 值的显著性检验，得到相应的 p 值， p_θ ：

如果 $p_\theta < \gamma$ ，则拒绝 θ 。

置信水平 $CL = 1 - \gamma$ 的置信区间包含没有被拒绝的 θ 值。

例如， θ 的上限 (upper limit) 是满足 $p_\theta \geq \gamma$ 的最大 θ 值。

实际应用中，令 $p_\theta = \gamma$ 并求解 θ 即得到最大 θ 值。

中心置信区间与单侧置信区间

有时，单独指定 α 或 β

→ 单边置信区间 (极限, 上限或下限)

通常，取 $\alpha = \beta = \gamma/2$

→ 覆盖概率为 $1 - \gamma$

→ 中心置信区间

注意：中心置信区间并不意味着区间对于 $\hat{\theta}$ 是对称的，它仅仅意味着 $\alpha = \beta$ 。

粒子与核物理的不确定度惯例是：68.3%的中心置信区间。

从似然函数估计近似的置信区间

假设利用似然比检验参数值 $\vec{\theta} = (\theta_1, \dots, \theta_n)$:

$$\lambda(\vec{\theta}) = \frac{L(\vec{\theta})}{L(\hat{\vec{\theta}})}$$

$$0 \leq \lambda(\vec{\theta}) \leq 1$$

$\lambda(\vec{\theta})$ 小 \rightarrow 数据与假设的 $\vec{\theta}$ 符合更差。等价地，通常定义


$$t_{\vec{\theta}} = -2 \ln \lambda(\vec{\theta})$$

$t_{\vec{\theta}}$ 大 \rightarrow 数据与假设的 $\vec{\theta}$ 符合得更差。

因此， $\vec{\theta}$ 的 p 值为:

$$p_{\vec{\theta}} = \int_{t_{\hat{\vec{\theta}}\text{obs}}}^{\infty} f(t_{\vec{\theta}}|\vec{\theta}) dt_{\vec{\theta}}$$

需要知道概率
密度 $f(t_{\vec{\theta}}|\vec{\theta})$



从Wilks定理估计置信区间

Wilks定理（满足大样本极限和其他一些条件）：

$$f(t_{\vec{\theta}}|\vec{\theta}) \sim \chi^2(n)$$

自由度数目等于参数 $\vec{\theta} = (\theta_1, \dots, \theta_n)$ 分量个数 n 的卡方分布

假设Wilks定理成立， p 值为

$$p_{\vec{\theta}} = 1 - F_{\chi^2(n)}(t_{\vec{\theta}})$$

要得到置信区间的边界，令 $p_{\vec{\theta}} = \alpha$ 并求解 $t_{\vec{\theta}}$ ：

$$t_{\vec{\theta}} = F_{\chi^2(n)}^{-1}(1 - \alpha)$$

注意， $t_{\vec{\theta}}$ 还可以表示为：

$$t_{\vec{\theta}} = -2 \ln \lambda(\vec{\theta}) = -2 \ln \frac{L(\vec{\theta})}{L(\hat{\vec{\theta}})} \longrightarrow \ln \vec{\theta} \text{ 可用 } F_{\chi^2(n)}^{-1} \text{ 表示}$$

从Wilks定理估计置信区间 (续)

在 $\vec{\theta}$ 空间, 置信区域的边界为

$$\ln L(\vec{\theta}) = \ln L(\hat{\vec{\theta}}) - \frac{1}{2} F_{\chi^2(n)}^{-1}(1 - \alpha)$$

例如, 对于 $1 - \alpha = 68.3\%$ 和 $n = 1$ 个参数

$$F_{\chi^2(n)}^{-1}(0.683) = 1$$

所以, 68.3%置信水平的置信区间由下式确定:


$$\ln L(\theta) = \ln L(\hat{\theta}) - \frac{1}{2}$$

这与求估计量标准差的方法一样, 即

$[\hat{\theta} - \sigma_{\hat{\theta}}, \hat{\theta} + \sigma_{\hat{\theta}}]$ 是 $CL = 68.3\%$ 的置信区间。

例：由 $\ln L(\theta)$ 求置信区间

对于 $n = 1$ 个参数, $CL = 68.3\%$, $Q_\alpha = F_{\chi^2(n)}^{-1}(1 - \alpha) = 1$ 。



在指数函数例子中, 只有 $n = 5$ 个观测值时:

可以报道ML估计值, 以利用 $\ln L_{\max} - \frac{1}{2}$ 得到的近似置信区间为 “不对称误差棒”:

$$\hat{\tau} = 0.85_{-0.30}^{+0.52}$$

多维参数置信区间

当参数个数增大时, 由 $Q_\alpha = F_{\chi^2(n)}^{-1}(1 - \alpha)$ 确定的置信区间的置信水平 $CL = 1 - \alpha$ 相应地降低。

Q_α	$1 - \alpha$				
	$n = 1$	$n = 2$	$n = 3$	$n = 4$	$n = 5$
1.0	0.683	0.393	0.199	0.090	0.037
2.0	0.843	0.632	0.428	0.264	0.151
4.0	0.954	0.865	0.739	0.594	0.451
9.0	0.997	0.989	0.971	0.939	0.891

多维参数置信区间 (续)

等价地, 对于给定 $CL = 1 - \alpha$, Q_α 随着 n 增大而增大。

$1 - \alpha$	Q_α				
	$n = 1$	$n = 2$	$n = 3$	$n = 4$	$n = 5$
0.683	1.00	2.30	3.53	4.72	5.89
0.90	2.71	4.61	6.25	7.78	9.25
0.95	3.84	5.99	7.82	9.49	11.1
0.99	6.63	9.21	11.3	13.3	15.1

讨论：检验/置信区间的要素

需要注意的是，我们只能利用观测数据计算得到的似然函数估计这些置信区间。这种做法可行的原因是，大样本极限下

统计量 $t_{\vec{\theta}} = -2 \ln \frac{L(\vec{\theta})}{L(\hat{\vec{\theta}})}$ 趋于定义明确的分布，与数据无关。

然而，对于有限样本，我们得到的区间是近似的。

通常来说，要做一个统计检验，需要知道检验统计量 $t(x)$ 的分布函数，这意味着需要知道 $P(x|\vec{\theta})$ 的完整信息。

泊松参数 s 的上限：频率论

考虑观测事例数 $n \sim \text{poi}(s + b)$, 假设 $b = 4.5$, $n_{\text{obs}} = 5$ 。
求置信水平 $\text{CL} = 95\%$ 的上限。

相关的备择假设是 $s = 0$ (小 n 时的临界域), 假设的 s 的
 p 值为 $P(n \leq n_{\text{obs}}; s, b)$, 求解下式得 $\text{CL} = 1 - \alpha$ 的上限 s_{up}

$$\alpha = P(n \leq n_{\text{obs}}; s_{\text{up}}, b) = \sum_{n=0}^{n_{\text{obs}}} \frac{(s_{\text{up}} + b)^n}{n!} e^{-(s_{\text{up}} + b)}$$

利用 $\sum_{n=0}^m \frac{v^n}{n!} e^{-v} = 1 - F_{\chi^2}(2v; n_d = 2(m + 1))$




$$\begin{aligned} s_{\text{up}} &= \frac{1}{2} F_{\chi^2}^{-1}(1 - \alpha; 2(n_{\text{obs}} + 1)) - b \\ &= \frac{1}{2} F_{\chi^2}^{-1}(0.95; 2(5 + 1)) - 4.5 = 6.0 \end{aligned}$$

泊松参数 s 的上限：频率论

对于事例数 n_{obs} 很小的涨落,

$$s_{\text{up}} = \frac{1}{2} F_{\chi^2}^{-1}(1 - \alpha; 2(n_{\text{obs}} + 1)) - b \quad \text{可以给出负的结果。}$$

即, 置信区间可能是空的。



给定 n_{obs} , 95% 置信水平下 s_{up} 随本底数 b 的变化关系。例如, 如果 $n_{\text{obs}} = 1$, $b = 6$, 那么 $s_{\text{up}} < 0$ 。

$$\alpha \geq 1 - F_{\chi^2}(2b; 2(n_{\text{obs}} + 1)) \text{ 时, } s_{\text{up}} \leq 0.$$


物理边界附近的极限

假设 $b = 2.5$ ，观测到 $n_{\text{obs}} = 0$ 。

$$s_{\text{up}} = \frac{1}{2} F_{\chi^2}^{-1}(1 - \alpha; 2(n_{\text{obs}} + 1)) - b = \frac{1}{2} F_{\chi^2}^{-1}(1 - \alpha; 2) - b$$

$$F_{\chi^2}^{-1}(x; 2) = -2 \ln(1 - x) \Rightarrow s_{\text{up}} = -\ln(\alpha) - b$$

如果选择 $\text{CL} = 1 - \alpha = 0.9$,



$$s_{\text{up}} = -\ln(0.1) - 2.5 = -0.197$$

物理学家：我们一开始就知道 $s \geq 0$ ；不能用负的上限报道昂贵实验的结果！

统计学家：置信区间按照定义只有 90% 的次数涵盖了真值——这无非是没覆盖真值的一次结果。

这种情况并不少见，尤其是在实验灵敏度很低的情况下检验参数值，例如信号 s 非常少的情况。

物理边界附近的极限 (续)

物理学家：我应当选 $CL = 0.95 \rightarrow s_{\text{up}} = 0.496$ 。

“更好的做法”： $CL = 0.917923 \rightarrow s_{\text{up}} = 10^{-4}!$



$$s_{\text{up}} = -0.197 \quad (CL = 0.90)$$

实际情况： $b = 2.5$ 时， n 的典型泊松涨落至少是 $\sqrt{2.5} = 1.6$ 。
上限怎么会这么小呢？

零信号假设 ($s = 0$) 下的平均上限：


取 $b = 2.5$, $CL = 0.95$

$n_{\text{obs}} \sim \text{Poi}(2.5)$, 对于给定的 n_{obs} , 上限为

$$s_{\text{up}}(n_{\text{obs}}) = \frac{1}{2} F_{\chi^2}^{-1}(0.95; 2(n_{\text{obs}} + 1)) - 2.5$$

平均上限： $\bar{s}_{\text{up}} = \sum_{n_{\text{obs}}=0}^{\infty} p(n_{\text{obs}}) s_{\text{up}}(n_{\text{obs}}) = 4.44$

$n_{\text{obs}} = 0$ 的概率为 8.2%



$b = 2.5, s = 0$ 时 $CL = 95\%$
上限 s_{up} 的分布。

贝叶斯方法确定上限

贝叶斯统计需要从“验前概率” $\pi(\theta)$ 出发，它反映实验前对于参数的信心程度。

贝叶斯定理给出，观测到数据 x 如何改进我们的信心程度：

$$p(\theta|x) = \frac{L(x|\theta)\pi(\theta)}{\int_{-\infty}^{+\infty} L(x|\theta')\pi(\theta')d\theta'} \propto L(x|\theta)\pi(\theta)$$

对验后概率 $p(\theta|x)$ 积分可给出任意期待概率下的区间。

例如，对于 $n \sim Poi(s + b)$ ，95% 置信水平下 s 的上限由下面的积分给出：

$$0.95 = \int_{-\infty}^{s_{\text{sup}}} p(s|n) ds$$

贝叶斯验前概率：泊松参数

考虑到 $s \geq 0$ ，可以要求 $s < 0$ 时 $\pi(s) = 0$ 。

一种“验前无倾向”的选择是：

$$\pi(s) = \begin{cases} 1 & s \geq 0 \\ 0 & \text{其他} \end{cases}$$

没有归一化，但只要 s 很大时 $L(s)$ 趋于零即可。

参数变化下不能保持不变。

并不真的反映合理的信心程度，但通常用来作为参考。

贝叶斯上限：均匀分布的 s 验前概率

将泊松似然函数和均匀分布的验前概率代入贝叶斯定理：


$$p(s|n) \propto \frac{(s+b)^n}{n!} e^{-(s+b)} \quad (s \geq 0)$$

归一化到单位面积：
$$p(s|n) = \frac{(s+b)^n e^{-(s+b)}}{\Gamma(b, n+1)}$$

分母
$$\begin{aligned} &= \int_0^\infty (s+b)^n e^{-(s+b)} ds \\ &= \int_b^\infty t^n e^{-t} dt \\ &= \Gamma(b, n+1) \end{aligned}$$

上不完全 Γ 函数

求解 $1 - \alpha = \int_0^{s_{\text{sup}}} p(s|n) ds$ 确定上限 s_{sup} 。

 $s_{\text{sup}} = \frac{1}{2} F_{\chi^2}^{-1}(p; 2(n+1)) - b$

其中 $p = 1 - \alpha(1 - F_{\chi^2}[2b, 2(n+1)])$

对特殊情况 $b = 0$ ，可得 $p = 1 - \alpha$ ，验前概率均匀的贝叶斯上限从数值上与单侧频率论结果相同（“巧合”）。

推导过程

$$1 - \alpha = \int_0^{s_{\text{sup}}} p(s|n) ds \Rightarrow s_{\text{sup}} \iff \alpha = \int_{s_{\text{sup}}}^{\infty} p(s|n) ds = \frac{\int_{s_{\text{sup}}}^{\infty} \frac{(s+b)^n}{n!} e^{-(s+b)} ds}{\int_0^{\infty} \frac{(s+b)^n}{n!} e^{-(s+b)} ds}$$

$$\text{分部积分: } \int_0^{\infty} \frac{(s+b)^n}{n!} e^{-(s+b)} ds = \int_b^{\infty} \frac{t^n}{n!} e^{-t} dt = \sum_{k=0}^n \frac{b^k}{k!} e^{-b}$$

$$\text{分部积分: } \int_{s_{\text{sup}}}^{\infty} \frac{(s+b)^n}{n!} e^{-(s+b)} ds = \int_{s_{\text{sup}}+b}^{\infty} \frac{t^n}{n!} e^{-t} dt = \sum_{k=0}^n \frac{(s_{\text{sup}}+b)^k}{k!} e^{-(s_{\text{sup}}+b)}$$

$$\text{利用 } \sum_{k=0}^m \frac{v^k}{k!} e^{-v} = 1 - F_{\chi^2}(2v; n_d = 2(m+1))$$

$$\Rightarrow \alpha = \frac{\sum_{k=0}^n \frac{(s_{\text{sup}}+b)^k}{k!} e^{-(s_{\text{sup}}+b)}}{\sum_{k=0}^n \frac{b^k}{k!} e^{-b}} = \frac{1 - F_{\chi^2}(2(s_{\text{sup}}+b); 2(n+1))}{1 - F_{\chi^2}(2b; 2(n+1))}$$


$$\Rightarrow F_{\chi^2}(2(s_{\text{sup}}+b); 2(n+1)) = 1 - \alpha (1 - F_{\chi^2}(2b; 2(n+1))) \equiv p$$

$$\Rightarrow 2(s_{\text{sup}}+b) = F_{\chi^2}^{-1}(p; 2(n+1)) \Rightarrow s_{\text{sup}} = \frac{1}{2} F_{\chi^2}^{-1}(p; 2(n+1)) - b$$

贝叶斯上限：均匀分布的 s 验前概率

对于 $b > 0$ ，贝叶斯上限处处都大于频率论上限。

- 1) 贝叶斯上限 $s_{\text{up}} > 0$
- 2) $n = 0$ 时，贝叶斯上限与 b 无关



$n = 0$ 时:

$$\alpha = \frac{\sum_{k=0}^n \frac{(s_{\text{up}}+b)^k}{k!} e^{-(s_{\text{up}}+b)}}{\sum_{k=0}^n \frac{b^k}{k!} e^{-b}}$$
$$= \frac{e^{-(s_{\text{up}}+b)}}{e^{-b}} = e^{-s_{\text{up}}}$$

$$\Rightarrow s_{\text{up}} = -\ln(\alpha) > 0$$

对于经典上限, $n = 0$ 时:

$$s_{\text{up}} = -\ln(\alpha) - b$$

$$\alpha \geq e^{-b} \text{ 时, } s_{\text{up}} \leq 0$$

由形式规则确定验前概率

由于很难将模糊的信心程度体现在验前概率中，人们经常尝试由形式规则（formal rules）确定验前概率，例如，要求满足某种不变原则，或者对某组测量提供最大的信息增益。

经常称其为“客观验前概率”
这构成了“客观贝叶斯统计”的基础

验前概率不反映信心程度（但可能表示可能的极端情形）。

在“客观贝叶斯”分析中，可以像频率论那样使用置信区间，即，将贝叶斯定理看作产生具有特定覆盖性质的区间的方法。

相关综述参见：R. E. Kass and L. Wasserman, *The Selection of Prior Distributions by Formal rules*, J. Am. Stat. Assoc., Vol. 91, 1343 (1996)

粒子物理中的应用：L. Demortier, S. Jain and H. Prosper, *Reference priors for high energy physics*, Phys. Rev. D82 (2010) 034002 [arXiv:1002.1111]

D. Casadei, Reference analysis of the signal + background model in counting experiments, JINST 7 (2012) 01012 [arXiv:1108.4270]

Jeffrey's 验前概率

根据 “Jeffrey 规则” , 验前概率取为

$$\pi(\vec{\theta}) \propto \sqrt{\det(I(\vec{\theta}))}$$

其中 $I(\vec{\theta})$ 是费舍尔信息矩阵:

$$I_{ij}(\vec{\theta}) = -E \left[\frac{\partial^2 \ln L(\vec{x}|\vec{\theta})}{\partial \theta_i \partial \theta_j} \right] = - \int \frac{\partial^2 \ln L(\vec{x}|\vec{\theta})}{\partial \theta_i \partial \theta_j} L(\vec{x}|\vec{\theta}) d\vec{x}$$

可以证明, 这种验前概率选择给出的推断在参数变换下不变。

对于高斯分布的均值 μ , Jeffrey 验前概率为常数;
对于泊松分布的均值 μ , Jeffrey 验前概率正比于 $1/\sqrt{\mu}$ 。

Jeffrey's 验前概率：泊松分布均值

假设 $n \sim Poi(\mu)$, 要得到 μ 的 Jeffrey 验前概率, 取

$$L(n|\mu) = \frac{\mu^n}{n!} e^{-\mu}$$

$$\frac{\partial^2 \ln L}{\partial \mu^2} = -\frac{n}{\mu^2}$$

$$I(\mu) = -E \left[\frac{\partial^2 \ln L}{\partial \mu^2} \right] = \frac{E[n]}{\mu^2} = \frac{1}{\mu}$$

$$\pi(\mu) \propto \sqrt{I(\mu)} = \frac{1}{\sqrt{\mu}}$$

例如, 对于 $\mu = s + b$, 这意味着验前概率 $\pi(s) \sim 1/\sqrt{s + b}$, 依赖于 b 。这不是关于 s 的信心程度。

搜索型分析

在某个相空间寻找信号，结果用变量 x 的直方图表示：

$$\vec{n} = (n_1, \dots, n_N)$$

假设 n_i 服从泊松分布，其均值为 $E[n_i] = \mu s_i + b_i$ ，其中

$$\text{信号 } s_i = s_{\text{tot}} \int_{\text{bin } i} f_s(x; \vec{\theta}_s) dx;$$

μ : 强度参数

$$\text{本底 } b_i = b_{\text{tot}} \int_{\text{bin } i} f_b(x; \vec{\theta}_b) dx$$

通常还有辅助测量，用来约束本底或形状参数：

$$\vec{m} = (m_1, \dots, m_M)$$

假设 m_i 服从泊松分布，其均值为 $E[m_i] = u_i(\vec{\theta})$ 。

似然函数为

冗余参数 $\vec{\theta}_s, \vec{\theta}_b, b_{\text{tot}}$

$$L(\mu, \vec{\theta}) = \prod_{j=1}^N \frac{(\mu s_j + b_j)^{n_j}}{n_j!} e^{-(\mu s_j + b_j)} \prod_{k=1}^M \frac{u_k^{m_k}}{m_k!} e^{-u_k}$$

搜索型实验的统计检验

考虑参数 μ ，正比于某尚未发现的信号过程的发生率。

假设描述数据的模型同时包含 μ 和一组冗余参数 $\vec{\theta}$ 。

为了检验假设的 μ 值，利用轮廓似然比 (profile likelihood ratio)

$$\lambda(\mu) = \frac{L(\mu, \hat{\hat{\theta}})}{L(\hat{\mu}, \hat{\hat{\theta}})}$$

$\hat{\hat{\theta}}$: 对指定的 μ 值使 L 最大

$\hat{\mu}, \hat{\hat{\theta}}$: 使 L 最大

物理发现或上限的检验统计量

物理发现：利用检验统计量 q_0 拒绝纯本底 ($\mu = 0$) 假设

$$q_0 = \begin{cases} -2 \ln \lambda(0), & \hat{\mu} \geq 0 \\ 0, & \hat{\mu} < 0 \end{cases}$$

即，我们把正的 μ 当作相关的备择假设，所以临界域选为对应于 $\hat{\mu}$ 值大的区域。

注意：尽管物理上 $\mu \geq 0$ ，我们在这里允许 $\hat{\mu}$ 为负值。在大样本极限下， $\hat{\mu}$ 服从高斯分布，从而检验统计量的分布可以化成简单的形式。

上限：为了对 μ 设定上限，利用 q_μ 作为检验统计量

$$q_\mu = \begin{cases} -2 \ln \lambda(\mu), & \hat{\mu} \leq 0 \\ 0, & \hat{\mu} > 0 \end{cases}$$

我们取相关的备择假设为 μ 较小，所以临界域定义为对应于 $\hat{\mu}$ 值小的区域。

轮廓似然比的 Wald 近似

为了求 p 值, 需要知道 $f(q_0|0)$ 和 $f(q_\mu|\mu)$ 。

对于备择假设下的中位数显著性, 需要知道 $f(q_\mu|\mu')$ 。

利用 Wald 近似:
$$-2 \ln \lambda(\mu) = \frac{(\mu - \hat{\mu})^2}{\sigma^2} + o(1/\sqrt{N})$$

$$\hat{\mu} \sim N(\mu', \sigma^2) \Rightarrow E[\hat{\mu}] = \mu'$$

N : 样本容量

σ 可从协方差矩阵得到:
$$V^{-1} = -E \left[\frac{\partial^2 \ln L}{\partial \theta_i \partial \theta_j} \right]$$

如果可以忽略 $o(1/\sqrt{N})$ 项, 则 $-2 \ln \lambda(\mu)$ 服从非中心的自由度为 1 的卡方分布, 非中心参数为

$$\Lambda = \frac{(\mu - \mu')^2}{\sigma^2}$$

特例: 如果 $\mu' = \mu$, 则 $\Lambda = 0$, $-2 \ln \lambda(\mu) \sim \chi^2(1)$ 【Wilks 定理】。

大样本极限下 q_0 的分布

假设大样本极限下近似成立，可以将 q_0 的完整分布写为

$$f(q_0|\mu') = \left(1 - \Phi\left(\frac{\mu'}{\sigma}\right)\right) \delta(q_0) + \frac{1}{2} \frac{1}{\sqrt{2\pi}} \frac{1}{\sqrt{q_0}} e^{-\frac{1}{2}\left(\sqrt{q_0} - \frac{\mu'}{\sigma}\right)^2}$$

$\mu' = 0$ 的特例是 “半卡方分布”：

$$f(q_0|0) = \frac{1}{2} \delta(q_0) + \frac{1}{2} \frac{1}{\sqrt{2\pi}} \frac{1}{\sqrt{q_0}} e^{-q_0/2}$$

在大样本极限下， $f(q_0|0)$ 与冗余参数无关； $f(q_0|\mu')$ 通过 σ 依赖于冗余参数。

大样本极限下 q_0 的累积分布、显著性

根据 q_0 的概率密度，其累积分布为

$$F(q_0|\mu') = \Phi\left(\sqrt{q_0} - \frac{\mu'}{\sigma}\right)$$

$\mu' = 0$ 的特例:


$$F(q_0|0) = \Phi(\sqrt{q_0})$$

$\mu = 0$ 假设的 p 值为

$$p_0 = 1 - F(q_0|0)$$

因此，物理发现的显著性 Z 为

$$Z = \Phi^{-1}(1 - p_0) = \sqrt{q_0}$$



G. Cowan, K. Cranmer, E. Gross, O. Vitells, EPJC 71 (2011) 1554 [arXiv:1007.1727]

上限 q_μ 的分布


对 q_μ 可以得到类似结果

$$f(q_\mu|\mu') = \Phi\left(\frac{\mu' - \mu}{\sigma}\right) \delta(q_\mu) + \frac{1}{2} \frac{1}{\sqrt{2\pi}} \frac{1}{\sqrt{q_\mu}} e^{-\frac{1}{2}\left(\sqrt{q_\mu} - \frac{(\mu - \mu')}{\sigma}\right)^2}$$

$$f(q_\mu|\mu) = \frac{1}{2} \delta(q_\mu) + \frac{1}{2} \frac{1}{\sqrt{2\pi}} \frac{1}{\sqrt{q_\mu}} e^{-\frac{q_\mu}{2}}$$

$$F(q_\mu|\mu') = \Phi\left(\sqrt{q_\mu} - \frac{(\mu - \mu')}{\sigma}\right)$$

$$p_\mu = 1 - F(q_\mu|\mu) = 1 - \Phi\left(\sqrt{q_\mu}\right)$$



注意：这是 CL_s 上限而不是似然比上限。
参见 G. Cowan, arXiv:1307.2487.

G. Cowan, K. Cranmer, E. Gross, O. Vitells, EPJC 71 (2011) 1554 [arXiv:1007.1727]

本底 b 不确定的轮廓似然函数

测量两个泊松变量:

$$\begin{array}{ll} n \sim \text{Poi}(s + b) & \text{(主测量或“搜索”测量)} \\ m \sim \text{Poi}(\tau b) & \text{(控制测量, } \tau \text{ 已知)} \end{array}$$

似然函数为

$$L(s, b) = \frac{(s + b)^n}{n!} e^{-(s+b)} \frac{(\tau b)^m}{m!} e^{-\tau b}$$

利用 L 构造轮廓似然比 (b 为冗余参数):

$$\lambda(0) = \frac{L(0, \hat{\hat{b}}(0))}{L(\hat{s}, \hat{b})}$$

需要的要素包括:

$$\hat{s} = n - m/\tau$$

$$\hat{b} = m/\tau$$

$$\hat{\hat{b}}(s) = \frac{n + m - (1 + \tau)s + \sqrt{(n + m - (1 + \tau)s)^2 + 4(1 + \tau)sm}}{2(1 + \tau)}$$

对于物理发现 ($s = 0$) 的检验: $\hat{\hat{b}}(0) = \frac{n + m}{(1 + \tau)}$

渐进显著性


利用: $\hat{s} = n - m/\tau$ $\hat{b} = m/\tau$ $\hat{b}(0) = \frac{n+m}{(1+\tau)}$

→
$$\lambda(0) = \frac{L(0, \hat{b}(0))}{L(\hat{s}, \hat{b})} = \left(\frac{n+m}{(1+\tau)n} \right)^n \left(\frac{\tau(n+m)}{(1+\tau)m} \right)^m$$

→
$$Z = \sqrt{q_0} = \sqrt{-2 \ln \lambda(0)}$$
$$= \left[-2 \left(n \ln \left[\frac{n+m}{(1+\tau)n} \right] + m \ln \left[\frac{\tau(n+m)}{(1+\tau)m} \right] \right) \right]^{1/2}$$
$$Z = 0 \quad n \leq \hat{b}$$
$$n > \hat{b}$$

期待的（或中位数）显著性/灵敏度

筹划实验时，我们希望量化实验对可能的发现的灵敏度，例如，在假定某个非零的强度参数 μ' 的情况下，通过给定的中位数显著性来量化。



求 p 值需要 $f(q_0 | 0)$ ；求灵敏度需要 $f(q_0 | \mu')$ 。

含本底的计数实验中期待的发现显著性

1. 本底 b 已知的计数实验的发现灵敏度:

(a) $\frac{s}{\sqrt{b}}$

(b) 轮廓似然比及Asimov近似: $\sqrt{2((s+b)\ln(1+s/b) - s)}$

2. 本底 b 不确定度为 σ_b 的发现灵敏度:

(a) $\frac{s}{\sqrt{b + \sigma_b^2}}$

(b) 轮廓似然比及Asimov近似:

$$\sqrt{2 \left((s+b) \ln \left(\frac{(s+b)(b + \sigma_b^2)}{b^2 + (s+b)\sigma_b^2} \right) - \frac{b^2}{\sigma_b^2} \ln \left[1 + \frac{\sigma_b^2 s}{b(b + \sigma_b^2)} \right] \right)}$$

本底已知的计数实验

实验记录事例数 $n \sim Poi(s + b)$, 其中

s = 期待的信号数

b = 期待的本底数

要检验信号的发现, 需要计算 $s = 0$ 假设的 p 值:

$$p = P(n \geq n_{\text{obs}} | b) = \sum_{n=n_{\text{obs}}}^{\infty} \frac{b^n}{n!} e^{-b} = 1 - F_{\chi^2}(2b; 2n_{\text{obs}})$$

通常将 p 值转换为等价的显著性: $Z = \Phi^{-1}(1 - p)$, 其中 Φ 是标准正态的累积分布, 例如, $Z > 5$ (5σ 效应) 意味着 $p < 2.9 \times 10^{-7}$ 。

要表征对发现的灵敏度, 可以给出给定 s 的假定下期望的 (均值或中位数) 显著性 Z 。

期待的发现显著性: s/\sqrt{b}

$s + b$ 很大时, $n \rightarrow x \sim N(\mu, \sigma^2)$, $\mu = s + b$, $\sigma^2 = s + b$ 。

对于观测值 x_{obs} , $s = 0$ 假设的 p 值为 $P(x > x_{\text{obs}} | s = 0)$:

$$p_0 = 1 - \Phi\left(\frac{x_{\text{obs}} - b}{\sqrt{b}}\right)$$

因此, 拒绝 $s = 0$ 的显著性为:

$$Z_0 = \Phi^{-1}(1 - p_0) = \frac{x_{\text{obs}} - b}{\sqrt{b}}$$

假定信号率为 s 时, 期待的 (中位数) 显著性为:

$$\text{median}[Z_0 | s + b] = \frac{s}{\sqrt{b}}$$

显著性的更好的近似

参数 s 的泊松似然函数为 $L(s) = \frac{(s+b)^n}{n!} e^{-(s+b)}$

为了检验某个发现，利用轮廓似然比：

$$q_0 = \begin{cases} -2 \ln \lambda(0), & \hat{s} \geq 0 \\ 0, & \hat{s} < 0 \end{cases}$$

$$\lambda(s) = \frac{L(s, \hat{\theta}(s))}{L(\hat{s}, \hat{\theta})}$$

此时没有
冗余参数

所以，检验 $s = 0$ 的似然比统计量为

$$q_0 = -2 \ln \frac{L(0)}{L(\hat{s})} = 2 \left(n \ln \frac{n}{b} + b - n \right)$$

($n > b$, 其他情况下 $q_0 = 0$)

$s + b$ 足够大时，利用 Wilks 定理

$$q_0 = \sqrt{2 \left(n \ln \frac{n}{b} + b - n \right)}$$

($n > b$, 其他情况下 $Z = 0$)

为了求 $\text{median}[Z|s]$ ，令 $n \rightarrow s + b$ (即Asimov数据集)：


$$Z_A = \sqrt{2((s+b) \ln(1+s/b) - s)}$$

$s \ll b$ 时，回到 s/\sqrt{b} 。

$s = 0$ 假设的中位数显著性的对比

$n \sim \text{Poi}(s + b)$, 假定 s 条件下 $s = 0$ 假设的中位数显著性:

CCGV, EPJC 71 (2011) 1554, arXiv:1007.1727



“Exact” :
来自MC, 数据离散导致跳跃。

$\sqrt{q_{0,A}}$:
在很大范围的 s 和 b 都是很好的近似。

s/\sqrt{b} :
仅在 $s \ll b$ 时符合得才较好近。

s/\sqrt{b} 推广到 b 不确定的情形

s/\sqrt{b} 的直观解释是，它比较的是信号 s 与零信号假设下 n 的标准差 \sqrt{b} 。

现在假设 b 的值不确定，其标准差为 σ_b 。

一个合理的猜测是，将 \sqrt{b} 替换为 \sqrt{b} 和 σ_b 的平方和，即

$$\text{median}[Z|s] = \frac{s}{\sqrt{b + \sigma_b^2}}$$

人们有时用这种方法优化某些分析，例如， σ_b 不可忽略的一些分析。

中位数显著性的Asimov近似

为了得到物理发现的中位数显著性，假定本底+信号模型，并用它们的期待值替换 n 和 m ： $n \rightarrow s + b$, $m \rightarrow \tau b$

$$\rightarrow Z_A = \left[-2 \left((s+b) \ln \left[\frac{s + (1+\tau)b}{(1+\tau)(s+b)} \right] + \tau b \ln \left[1 + \frac{s}{(1+\tau)b} \right] \right) \right]^{1/2}$$

或者利用 $\hat{b} = m/\tau$ 的方差 $V[\hat{b}] \equiv \sigma_b^2 = b/\tau$ 消除 τ ：


$$Z_A = \left[2 \left((s+b) \ln \left[\frac{(s+b)(b+\sigma_b^2)}{b^2 + (s+b)\sigma_b^2} \right] - \frac{b^2}{\sigma_b^2} \ln \left[1 + \frac{\sigma_b^2 s}{b(b+\sigma_b^2)} \right] \right) \right]^{1/2}$$

按 s/b 和 $\sigma_b^2/b (= 1/\tau)$ 展开得到：


$$Z_A = \frac{s}{\sqrt{b + \sigma_b^2}} \left(1 + \mathcal{O}(s/b) + \mathcal{O}(\sigma_b^2/b) \right)$$

所以，“直观的”公式可以解释为一种极限情形，即将轮廓似然比检验用于Asimov数据集。

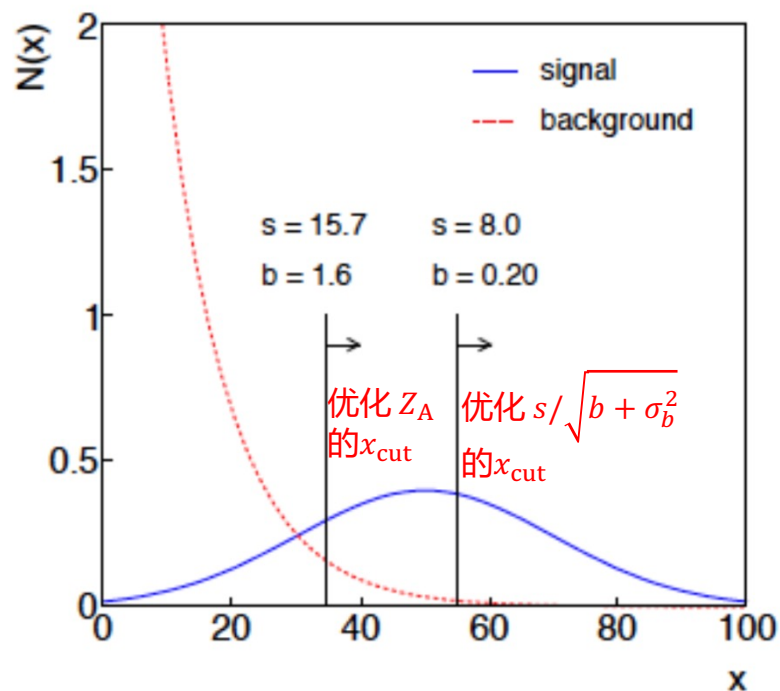
几个公式的对比: $s = 5$



用显著性/灵敏度优化事例筛选




期待的显著性随筛选条件 x_{cut} 的变化。



信号与本底的分布及不同的事例筛选结果。


对 μ 的检验灵敏度很低的情形

有时，给定假设的 μ 的效应相对于纯本底 ($\mu = 0$) 预言的效应很小。这意味着 $f(q_\mu|\mu)$ 和 $f(q_\mu|0)$ 几乎相同：



对 μ 的检验灵敏度很高的情形


如果对 μ 的检验灵敏度很高, 意味着 $f(q_\mu|\mu)$ 和 $f(q_\mu|0)$ 明显不同:



即, 检验效力 ($\mu = 0$ 时拒绝 μ 的概率) 显著高于 α 。
这个效力可以表征灵敏度。

不可靠的假设排除情形

考虑低灵敏度。 μ 为真时拒绝 μ 的概率为 α (例如5%) , 而 $\mu = 0$ 时拒绝 μ 的概率 (效力) 稍大于 α 。



这意味着, 我们将以稍大于 $\alpha = 5\%$ 的概率拒绝 μ 为真的假设, 但几乎没有灵敏度。

这称为 “不可靠的假设排除”。

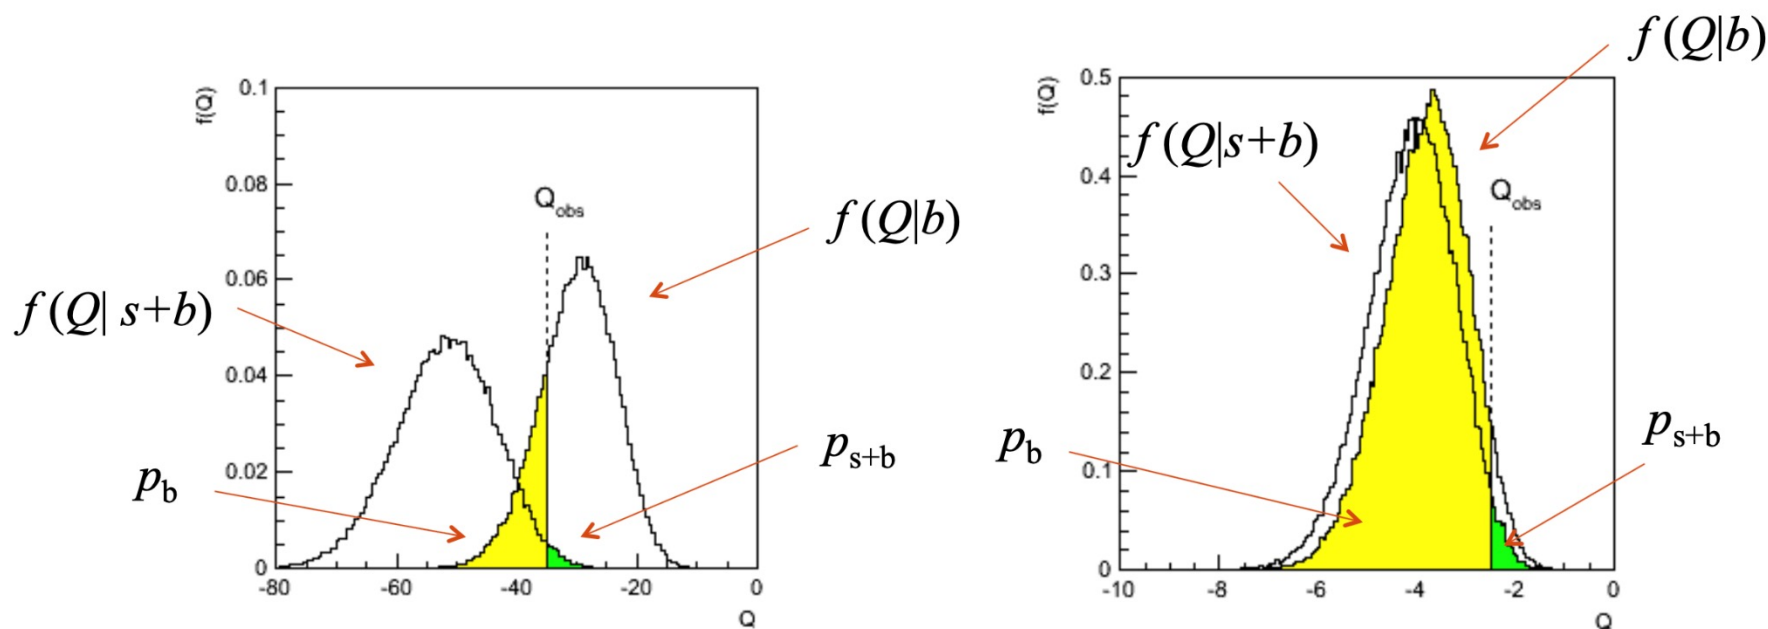
为了解决这个问题, 提出了 “CL_s” 方法设置上限。

T. Junk, Nucl. Instrum. Methods Phys. Res., Sec. A 434, 435 (1999);
A. L. Read, J. Phys. G 28, 2693 (2002).

CL_s 方法

在通常的CL_s表示中，我们用同一个统计量 $Q = -2 \ln L_{s+b} / L_b$ 同时检验假设 $\mu = 0$ (b) 和 $\mu > 0$ ($\mu s + b$)。

“灵敏度低”意味着在 b 和 $s + b$ 假设下 Q 的分布非常接近。




CL_s 方法 (续)

CL_s的做法是，检验不基于通常的 p 值 (CL_{s+b}) 而是基于 CL_{s+b} 与 CL_b 的比值，即定义

$$CL_s = \frac{CL_{s+b}}{CL_b} = \frac{p_{s+b}}{1 - p_b}$$

如果 $CL_s \leq \alpha$,
则拒绝 $s + b$ 假设。




当两个分布离得越来越近时，则提高 “有效的” p 值（防止灵敏度太低时得出排除结论）。

对 $\mu = \sigma/\sigma_{\text{SM}}$ 设置上限

对参数 $\mu = \sigma/\sigma_{\text{SM}}$ 实施 CL_s 步骤，得到上限 μ_{up} 。

例如，寻找希格斯粒子，定义 $\mu = m_H/m_H^{\text{SM}}$ 。对于每个给定的 m_H 值，有一个 μ_{up} 的观测值，也可以得到分布 $f(\mu_{\text{up}}|0)$ 。




$\pm 1\sigma$ (绿色)和 $\pm 2\sigma$ (黄色)条带
来自简易模拟 (toy MC) ;

竖线来自渐进公式。

如何理解上限图

对每个 m_H 值, 求 μ 的 CL_s 上限, 并确定 $\mu = 0$ 假设下得到的上限 μ_{up} 的分布。

虚线是中位数 μ_{up} , 绿色 (黄色) 条带给出这个分布的 $\pm 1\sigma$ (2σ) 范围。



ATLAS, Phys. Lett. B 710 (2012) 49

小结

- 统计不确定度中的标准差问题
- 经典置信区间问题
- 利用似然函数或二乘函数确定置信区间
- 贝叶斯上限
- 物理发现或上限的检验统计量